ANALISIS SPASIAL SEBARAN TITIK PANAS KEBAKARAN HUTAN DAN LAHAN TERHADAP KEPADATAN DRAINASE DAN JARAK TERHADAP JALAN

(Studi Kasus: Kota Palangka Raya, Agustus 2026)

Disusun Oleh:
Andini Azkiyatus Salsabila
6016261025

Untuk memenuhi *project-based case* mata kuliah:
Pemrograman Data Spasial

Dosen Pengampu:
Dr. Filsa Bioresita, S.T., M.T.
NIP. 199107192015042002

Program Studi Magister Teknik Geomatika
Departemen Teknik Geomatika
Fakultas Teknik Sipil, Perencanaan, dan Kebumian
Oktober 2026

DAFTAR ISI

DAFTAR ISI 1
DAFTAR GAMBAR 4
DAFTAR TABEL 5
BAB I 6
PENDAHULUAN 6
1.1 Latar Belakang 6
1.2 Rumusan Masalah 6
1.3 Tujuan 7
1.4 Batasan Masalah 7
1.5 Manfaat 7
BAB II 9
TINJAUAN PUSTAKA 9
2.1 Kebakaran Hutan dan Lahan 9
2.2 Penginderaan Jauh 10
2.3 Analisis Statistik 11
2.3.1 Regresi Linear 11
2.3.2 Autokorelasi Spasial 12
2.4 Bahasa Pemrograman R 14
2.5 Indeks Spektral 15
2.5.1 Normalized Difference Vegetation Index (NDVI) 15
2.5.2 Normalized Burn Ratio (NBR) 15
BAB III 17
METODOLOGI 17
3.1 Lokasi Penelitian 17
3.2 Bahan dan Peralatan 18
3.2.1 Bahan 18
3.2.2 Peralatan 19
3.3 Metode Penelitian 19
3.3.1 Tahapan Pelaksanaan Penelitian 19
3.3.2 Tahapan Pengolahan Data 20
3.3.3 Langkah Pengerjaan 22
BAB IV 33

HASIL DAN PEMBAHASAN 33
4.1 Hasil 33
4.1.1 Hasil Regresi Linear 33
4.1.2 Hasil Autokorelasi Spasial Global (Global Moran's I) 36
4.1.3 Hasil Autokorelasi Spasial Lokal (LISA) 38
4.1.4 Hasil Getis-Ord-Gi* 41
4.1.5 Hasil Pengolahan Indeks Spektral Sentinel-2 44
4.2 Pembahasan 49
4.2.1 Persebaran Spasial Titik Panas dan Kesesuaiannya dengan Kondisi Karhutla 2026 49
4.2.2 Hubungan Kepadatan Drainase dan Jarak terhadap Jalan dengan Titik Panas 50
4.2.3 Perbedaan Autokorelasi Spasial antara Unit Satuan Kelurahan dan Grid 51
4.2.4 Keterkaitan NDVI dan NBR dengan Aktivitas Kebakaran dan Kondisi Vegetasi 52
BAB V 56
KESIMPULAN 56
5.1 Kesimpulan 56
5.2 Saran 56
DAFTAR PUSTAKA 58
LAMPIRAN 61

DAFTAR GAMBAR

Gambar 3.1 Kabupaten dan Kota di Kalimantan Tengah 17
Gambar 3.2 Lokasi penelitian yang dipilih 18
Gambar 3.3 Tahap pengolahan data 20
Gambar 4.1 Scatterplot regresi linear tunggal dengan satuan analisis kelurahan 34
Gambar 4.2 Scatterplot regresi linear tunggal dengan satuan analisis grid 1 x 1 kilometer 34
Gambar 4.3 Moran plot kepadatan titik panas pada unit satuan kelurahan (kiri) dan unit satuan grid (kanan) 37
Gambar 4.4 Moran plot kepadatan drainase pada unit satuan kelurahan (kiri) dan unit satuan grid (kanan) 37
Gambar 4.5 Moran plot rata-rata jarak terhadap jalan pada unit satuan kelurahan (kiri) dan unit satuan grid (kanan) 38
Gambar 4.6 Peta klasifikasi LISA kepadatan titik panas pada satuan kelurahan (kiri) dan satuan grid (kanan) 39
Gambar 4.7 Peta klasifikasi LISA kepadatan drainase pada satuan kelurahan (kiri) dan satuan grid (kanan) 40
Gambar 4.8 Peta klasifikasi LISA rata-rata jarak terhadap jalan pada satuan kelurahan (kiri) dan satuan grid (kanan) 40
Gambar 4.9 Peta klasifikasi Getis-Ord Gi* kepadatan titik panas pada satuan kelurahan (kiri) dan satuan grid (kanan) 42
Gambar 4.10 Peta klasifikasi Getis-Ord Gi* kepadatan drainase pada satuan kelurahan (kiri) dan satuan grid (kanan) 43
Gambar 4.11 Peta klasifikasi Getis-Ord Gi* rata-rata jarak terhadap jalan pada satuan kelurahan (kiri) dan satuan grid (kanan) 43
Gambar 4.12 Peta persebaran kelas NDVI dan grafik distribusi luas bulan (a) Juli 2026, (b) Agustus 2026, dan (c) September 2026 46
Gambar 4.13 Peta persebaran kelas NBR dan grafik distribusi luas bulan (a) Juli 2026, (b) Agustus 2026, dan (c) September 2026 48
Gambar 4.14 Tren perubahan luas wilayah kategori NDVI dan NBR Kota Palangka Raya periode Juli - September 2026 52
Gambar 4.15 Tren perubahan luas wilayah kategori NDVI dan NBR (tanpa Rapat dan Sehat) Kota Palangka Raya periode Juli - September 2026 53

DAFTAR TABEL

Tabel 2.1 Kategori LISA 13
Tabel 3.1 Spesifikasi perangkat keras yang digunakan 19
Tabel 4.1 Ringkasan hasil regresi linear tunggal dari masing-masing variabel terhadap kepadatan titik panas 33
Tabel 4.2 Ringkasan hasil regresi linear berganda terhadap kepadatan titik panas 35
Tabel 4.3 Hasil uji Global Moran's I pada satuan kelurahan dan grid 36
Tabel 4.4 Jumlah dan tingkat signifikansi tiap *cluster* pada tiap variabel dan unit satuan analisis 38
Tabel 4.5 Jumlah *cluster* berdasarkan hasil Getis-Ord-Gi* 41
Tabel 4.6 Kelurahan dengan Getis-Ord Gi* signifikan menurut variabel 41
Tabel 4.7 Kelurahan dengan Getis-Ord Gi* signifikan menurut variabel 42
Tabel 4.8 Luas kategori klasifikasi NDVI per bulan 44
Tabel 4.9 Luas kategori klasifikasi NBR per bulan 46

BAB I
PENDAHULUAN

1.1 Latar Belakang

Kebakaran hutan dan lahan (karhutla) merupakan permasalahan lingkungan yang berulang di Indonesia, khususnya pada kawasan dengan mayoritas lahan gambut seperti Kalimantan Tengah. Kota Palangka Raya, Kalimantan Tengah memiliki wilayah dengan karakteristik lahan dan aktivitas manusia yang perlu diperhatikan dalam pemantauan karhutla. Lahan gambut yang mengalami pengeringan menjadi lebih rentan terbakar karena material organik kehilangan kelembapannya, selain itu api juga dapat menjalar pada lapisan gambut di bawah permukaan. Pengeringan dan degradasi gambut dapat meningkatkan kerentanan terhadap kebakaran. Pentingnya pemantauan turut diperlihatkan oleh publikasi Pantau Gambut (2026) mengenai konsentrasi titik panas di Kalimantan pada September 2026.

Distribusi titik panas dapat berhubungan dengan faktor fisik maupun aktivitas manusia. Jaringan drainase berpotensi memengaruhi kondisi tata air, terutama pada lahan gambut, sedangkan keberadaan jalan berkaitan dengan aksesibilitas dan aktivitas manusia. Pantau Gambut (t.t.) menjelaskan bahwa sekat dan penimbunan kanal digunakan untuk menahan keluarnya air dari gambut sebagai bagian dari upaya pembasahan kembali. Meskipun demikian, keterkaitan kepadatan drainase dan jarak terhadap jalan dengan distribusi titik panas perlu diuji secara statistik dan tidak dapat langsung dimaknai sebagai hubungan sebab-akibat.

Penginderaan jauh memungkinkan pengamatan indikasi kebakaran dan kondisi permukaan lahan secara spasial. Produk titik panas Visible Infrared Imaging Radiometer Suite (VIIRS) dengan resolusi spasial 375 meter dapat digunakan untuk memetakan deteksi anomali termal NASA (t.t.). Sementara itu, citra Sentinel-2 memungkinkan penghitungan Normalized Difference Vegetation Index (NDVI) dan Normalized Burn Ratio (NBR) untuk menggambarkan kondisi vegetasi dan karakteristik spektral lahan. Kedua indeks tersebut merupakan informasi pelengkap dan tidak secara otomatis menjadi ukuran luas kebakaran yang terverifikasi.

Berdasarkan hal tersebut, penelitian ini menganalisis persebaran titik panas di Kota Palangka Raya pada Agustus 2026 beserta hubungannya dengan kepadatan drainase dan jarak terhadap jalan. Analisis dilakukan pada unit kelurahan/desa dan grid 1 × 1 km untuk melihat perbedaan pola pada dua satuan spasial. Analisis NDVI dan NBR periode Juli–September 2026 turut digunakan untuk memberikan gambaran kondisi vegetasi dan lahan. Pengolahan berbasis bahasa pemrograman R diharapkan menghasilkan informasi pendukung bagi penentuan prioritas pemantauan karhutla.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang dipaparkan, penelitian ini memiliki rumusan masalah sebagai berikut:

1. Bagaimana distribusi dan kepadatan titik panas di Kota Palangka Raya pada satuan administrasi kelurahan/desa dibandingkan dengan satuan *grid* 1 x 1 km?

2. Bagaimana hubungan antara kepadatan titik panas dengan kepadatan drainase serta rata-rata jarak terhadap jalan berdasarkan hasil analisis regresi linear sederhana dan berganda?
3. Bagaimana pola autokorelasi spasial global, pemusatan klaster lokal (LISA), dan konsentrasi titik panas (*hotspot/coldspot* Getis–Ord Gi^*) pada ketiga variabel tersebut?
4. Bagaimana pola distribusi serta perubahan luasan kategori vegetasi dan kondisi kebasahan lahan berdasarkan indeks NDVI dan NBR pada periode Juli–September 2026?

1.3 Tujuan

Berdasarkan latar belakang dan rumusan masalah yang dipaparkan, penelitian ini memiliki tujuan sebagai berikut:

1. Menganalisis distribusi dan kepadatan titik panas di Kota Palangka Raya pada satuan administrasi kelurahan/desa dan grid 1 x 1 km.
2. Mengidentifikasi hubungan kepadatan titik panas dengan kepadatan drainase dan rata-rata jarak terhadap jalan melalui regresi linear sederhana dan berganda.
3. Mengidentifikasi pola autokorelasi, klaster lokal, dan konsentrasi spasial pada ketiga variabel menggunakan Global Moran's I, LISA, dan Getis–Ord Gi*.
4. Menggambarkan distribusi serta perubahan luasan kategori vegetasi dan kondisi lahan berdasarkan NDVI dan NBR pada Juli–September 2026.

1.4 Batasan Masalah

Berdasarkan tujuan penelitian serta latar belakang yang telah dipaparkan, penelitian ini memiliki batasan masalah sebagai berikut:

1. Wilayah kajian dibatasi pada Kota Palangka Raya, Kalimantan Tengah, dengan unit analisis kelurahan/desa dan grid 1 × 1 km.
2. Data titik panas berasal dari VIIRS periode 1–31 Agustus 2026 yang akan dilakukan agregasi untuk menghindari duplikasi data dari beberapa satelit.
3. Variabel analisis regresi dan autokorelasi spasial meliputi kepadatan titik panas, kepadatan jaringan sungai dan irigasi sebagai drainase, serta rata-rata jarak terhadap jalan.
4. Hubungan spasial dibentuk menggunakan prinsip queen contiguity dengan metode autokorelasi meliputi Global Moran's I, LISA, dan Getis–Ord Gi*.
5. Analisis Sentinel-2 dibatasi pada klasifikasi indeks NDVI dan NBR serta perbandingan luasan kategori pada Juli, Agustus, dan September 2026.
6. Penelitian bersifat eksploratif dan tidak ditujukan untuk membuktikan kausalitas, memprediksi kebakaran, maupun menetapkan luas area terbakar secara definitif.

1.5 Manfaat

Secara akademis, penelitian ini diharapkan memperkaya penerapan penginderaan jauh, regresi linear, dan autokorelasi spasial untuk memahami pola persebaran titik panas serta keterkaitannya dengan variabel lingkungan dan aksesibilitas. Perbandingan antara satuan

administrasi dan grid juga dapat memberi gambaran mengenai pengaruh pilihan unit analisis terhadap pola spasial yang teridentifikasi.

Secara praktis, hasil penelitian dapat menjadi informasi pendukung bagi instansi terkait untuk mengenali wilayah dengan konsentrasi titik panas yang signifikan serta mempertimbangkan prioritas pemantauan. Informasi NDVI dan NBR turut memberikan gambaran awal kondisi vegetasi dan lahan dalam mendukung evaluasi lingkungan dan mitigasi karhutla.

BAB II
TINJAUAN PUSTAKA

2.1 Kebakaran Hutan dan Lahan

Kebakaran hutan dan lahan (karhutla) merupakan peristiwa terbakarnya vegetasi serta material organik yang berada di suatu kawasan hutan maupun lahan terbuka. Kebakaran dapat dipicu oleh aktivitas manusia ataupun faktor alami, sedangkan perkembangan dan penyebarannya dipengaruhi oleh kondisi cuaca, ketersediaan bahan bakar, karakteristik vegetasi, dan keadaan lingkungan setempat. Karhutla menjadi salah satu permasalahan lingkungan yang mendapat perhatian besar di Indonesia karena tidak hanya menyebabkan kerusakan ekosistem, tetapi juga menghasilkan emisi karbon, menurunkan kualitas udara, serta mengganggu aktivitas masyarakat.

Kalimantan Tengah merupakan salah satu wilayah yang memiliki kerentanan terhadap karhutla, terutama karena keberadaan ekosistem gambut yang cukup luas. Berbeda dengan tanah mineral, tanah gambut terbentuk dari akumulasi bahan organik yang terdekomposisi secara tidak sempurna dalam kondisi jenuh air. Ketika muka air tanah mengalami penurunan, lapisan gambut menjadi lebih kering dan rentan terbakar. Kebakaran pada lahan gambut juga dapat berlangsung di bawah permukaan tanah dalam bentuk pembakaran membara (*smouldering combustion*), sehingga lebih sulit dideteksi dan dipadamkan dibandingkan kebakaran vegetasi di permukaan.

Page dkk. (2002), melalui penelitian kebakaran gambut dan hutan di Kalimantan Tengah pada 1997, menunjukkan bahwa pembakaran gambut dapat melepaskan karbon dalam jumlah besar ke atmosfer. Penelitian tersebut memperkirakan bahwa kebakaran gambut dan vegetasi di Indonesia pada 1997 menghasilkan emisi sebesar 0,81–2,57 gigaton karbon. Temuan ini memperlihatkan bahwa dampak karhutla tidak hanya berkaitan dengan luas area yang terbakar, tetapi juga dengan karakteristik material yang mengalami pembakaran.

Kondisi tersebut relevan dengan Kota Palangka Raya, yang memiliki kawasan bergambut di sejumlah wilayahnya. Kerentanan lahan terhadap kebakaran berkaitan dengan kondisi hidrologi gambut, tutupan vegetasi, serta aktivitas pemanfaatan lahan. Perubahan tutupan lahan dan drainase yang menurunkan muka air tanah dapat meningkatkan kemungkinan mengeringnya bahan organik. Pada musim dengan curah hujan rendah, kondisi ini dapat memperbesar risiko terjadinya kebakaran. Meskipun demikian, tingkat kerentanan tidak selalu sama pada seluruh wilayah karena sifat lahan, kelembapan, penggunaan lahan, dan keberadaan sumber penyalaan dapat berbeda antar lokasi.

Dalam bidang geospasial, karhutla perlu dipahami sebagai fenomena yang memiliki dimensi ruang dan waktu. Kejadian kebakaran tidak selalu tersebar secara merata, melainkan dapat terkonsentrasi pada lokasi tertentu akibat kemiripan kondisi lingkungan atau aktivitas penggunaan lahan. Pola persebaran tersebut dapat dipelajari melalui data penginderaan jauh dan metode statistik spasial untuk mengidentifikasi konsentrasi kebakaran, keterkaitan antarwilayah, serta karakteristik lingkungan yang berhubungan dengan kejadian karhutla.

2.2 Penginderaan Jauh

Penginderaan jauh merupakan teknik memperoleh informasi mengenai objek atau fenomena di permukaan bumi tanpa melakukan kontak langsung dengan objek tersebut. Informasi diperoleh melalui sensor yang merekam energi elektromagnetik yang dipantulkan, dipancarkan, atau dihamburkan oleh objek. Lillesand dkk. (2015) menjelaskan bahwa penginderaan jauh memungkinkan pengamatan karakteristik permukaan bumi melalui proses perekaman, pengolahan, dan interpretasi data sensor.

Dalam pengamatan permukaan bumi, interaksi antara radiasi elektromagnetik dan objek dipengaruhi oleh sifat fisik maupun kimia material. Vegetasi sehat, misalnya, cenderung menyerap energi pada panjang gelombang merah untuk proses fotosintesis, tetapi memantulkan energi relatif tinggi pada wilayah inframerah dekat (*near-infrared* atau NIR). Sebaliknya, tanah terbuka, vegetasi kering, dan area bekas kebakaran memiliki karakteristik respons spektral yang berbeda. Perbedaan tersebut menjadi dasar penggunaan citra satelit untuk mengidentifikasi kondisi vegetasi dan perubahan permukaan lahan.

Sistem penginderaan jauh dapat dibedakan menjadi sensor pasif dan aktif berdasarkan sumber energinya. Sensor pasif memanfaatkan energi alami, seperti pantulan sinar matahari atau radiasi termal yang dipancarkan objek, sedangkan sensor aktif menghasilkan energi sendiri untuk mengamati permukaan bumi. Dalam pemantauan karhutla, sensor optik multispektral dan sensor inframerah termal memiliki peran yang saling melengkapi. Sensor multispektral dapat digunakan untuk mengamati kondisi vegetasi serta perubahan akibat kebakaran, sementara sensor termal dapat membantu mengidentifikasi anomali panas yang berkaitan dengan aktivitas pembakaran.

Salah satu contoh sensor pasif yaknik satelit Sentinel-2. Sentinel-2 merupakan misi pengamatan bumi dalam program Copernicus yang dikembangkan oleh European Space Agency (ESA). Satelit ini menggunakan sensor *MultiSpectral Instrument* (MSI) yang merekam informasi pada 13 kanal spektral, mulai dari cahaya tampak hingga inframerah gelombang pendek. Sentinel-2 menyediakan kanal dengan resolusi spasial 10, 20, dan 60 meter, bergantung pada panjang gelombang yang direkam (European Space Agency, t.t.). Dalam analisis vegetasi dan area bekas kebakaran, Sentinel-2 dapat digunakan untuk menghitung indeks spektral seperti *Normalized Difference Vegetation Index* (NDVI) dan *Normalized Burn Ratio* (NBR). Kombinasi kanal NIR dan SWIR juga membantu membedakan vegetasi sehat dari permukaan yang mengalami perubahan setelah kebakaran.

Contoh lain dari satelit pasif yakni penggunaan sensor VIIRS pada beberapa satelit. *Visible Infrared Imaging Radiometer Suite* (VIIRS) merupakan sensor penginderaan jauh yang digunakan untuk pengamatan berbagai fenomena di permukaan bumi, termasuk anomali panas akibat aktivitas kebakaran. Data deteksi kebakaran aktif dari VIIRS tersedia dan dapat diakses melalui layanan *Fire Information for Resource Management System* (FIRMS) yang dikembangkan NASA. Produk deteksi kebakaran VIIRS dengan resolusi nominal 375 meter memiliki kemampuan mendeteksi kebakaran berukuran relatif kecil dengan lebih baik dibandingkan produk MODIS beresolusi sekitar 1 kilometer. VIIRS juga mendukung

pengamatan malam hari, sehingga berguna dalam pemantauan aktivitas kebakaran pada waktu yang berbeda (NASA FIRMS, t.t.).

2.3 Analisis Statistik

Analisis statistik merupakan metode yang digunakan untuk mengolah, menyajikan, dan menafsirkan data sehingga hubungan maupun pola di dalamnya dapat dipahami secara sistematis. Dalam bidang geospasial, analisis statistik tidak hanya memperhatikan nilai suatu variabel, tetapi juga dapat mempertimbangkan lokasi dan hubungan keruangan antarpengamatan untuk menentukan klusterisasi dari data secara spasial.

Dua pendekatan statistik yang digunakan dalam kajian ini adalah regresi linear dan autokorelasi spasial. Regresi linear berfokus pada hubungan antara variabel respons dan variabel penjelas, sedangkan autokorelasi spasial digunakan untuk mengevaluasi hubungan antarnilai berdasarkan lokasi geografisnya.

2.3.1 Regresi Linear

Regresi linear merupakan metode statistik yang digunakan untuk memodelkan hubungan antara suatu variabel respons dengan satu atau lebih variabel penjelas. Metode ini bertujuan memperkirakan perubahan nilai variabel respons berdasarkan perubahan variabel penjelas, dengan mengasumsikan bahwa hubungan tersebut dapat direpresentasikan melalui model yang linear terhadap parameternya (Montgomery dkk., 2021).

Terdapat dua jenis regresi yang banyak digunakan yakni regresi linear tunggal/sederhana dan regresi linear berganda. Regresi linear sederhana digunakan ketika suatu variabel respons dianalisis berdasarkan satu variabel penjelas. Bentuk umum model regresi linear sederhana dinyatakan melalui Persamaan (2.1).

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i \qquad (2.1)$$

Keterangan:

- Y_i adalah nilai variabel dependen pada pengamatan ke-i
- X_i adalah nilai variabel independen
- β_0 merupakan intersep atau konstanta
- β_1 adalah koefisien regresi
- ε_i merupakan komponen *error*
- i menunjukkan indeks pengamatan.

Koefisien β_1 menunjukkan besarnya perubahan nilai rata-rata Y yang diperkirakan terjadi setiap kenaikan satu satuan X. Koefisien positif menunjukkan hubungan searah, sedangkan koefisien negatif menunjukkan hubungan berlawanan arah.

Regresi linear berganda merupakan pengembangan regresi linear sederhana yang melibatkan dua atau lebih variabel penjelas. Pendekatan ini memungkinkan beberapa faktor dianalisis secara bersamaan sehingga hubungan suatu variabel dengan variabel respons dapat diperkirakan dengan mempertimbangkan variabel lain dalam model.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_p X_{pi} + \varepsilon_i \qquad (2.2)$$

Keterangan:

- $X_{1i}, X_{2i}, \ldots, X_{pi}$ merupakan variabel penjelas
- $\beta_1, \beta_2, \ldots, \beta_p$ adalah koefisien regresi untuk masing-masing variabel
- Parameter p menunjukkan jumlah variabel penjelas dalam model.

Parameter regresi umumnya diestimasi menggunakan metode Ordinary Least Squares (OLS), yang mencari nilai koefisien dengan meminimalkan jumlah kuadrat selisih antara nilai pengamatan dan nilai prediksi.

$$\min_{\beta_0,\ldots,\beta_p} \sum_{i=1}^{n} \left(Y_i - \hat{Y}_i\right)^2 \qquad (2.3)$$

dengan Y_i merupakan nilai pengamatan dan $\hat{Y}_i$ merupakan nilai hasil prediksi model.

Kualitas model dapat dievaluasi melalui koefisien determinasi (R^2), pengujian signifikansi koefisien, maupun pemeriksaan residual. Penggunaan regresi linear juga perlu memperhatikan asumsi linearitas, independensi galat, kesamaan varians galat (homoskedastisitas), dan tidak adanya multikolinearitas yang kuat pada variabel penjelas. Asumsi normalitas galat terutama relevan untuk inferensi parametrik dalam sampel kecil (Montgomery dkk., 2021).

2.3.2 Autokorelasi Spasial

Autokorelasi spasial merupakan konsep statistik yang menjelaskan hubungan antara nilai suatu variabel pada lokasi berbeda berdasarkan kedekatan atau keterhubungan geografis. Konsep ini berangkat dari kenyataan bahwa pengamatan di suatu lokasi tidak selalu independen terhadap pengamatan di lokasi sekitarnya.

Dalam fenomena lingkungan, wilayah yang berdekatan sering kali memiliki kondisi yang saling berkaitan, seperti karakteristik tanah, tutupan vegetasi, curah hujan, atau penggunaan lahan. Kondisi tersebut dapat menghasilkan kemiripan nilai pada lokasi-lokasi yang berdekatan.

Autokorelasi spasial positif terjadi ketika lokasi yang berdekatan cenderung memiliki nilai yang serupa, baik sama-sama tinggi maupun sama-sama rendah. Sebaliknya, autokorelasi spasial negatif terjadi ketika lokasi yang berdekatan cenderung memiliki nilai yang berbeda. Apabila tidak terdapat pola hubungan spasial yang terdeteksi secara signifikan, distribusi nilai dapat dianggap tidak menunjukkan bukti autokorelasi spasial berdasarkan pengujian dan struktur ketetanggaan yang digunakan. Terdapat berbagai jenis metode untuk mengecek autokorelasi spasial pada suatu data, pada penelitian ini akan menggunakan 3 metode yakni Global Moran's I, Local Indicators of Spatial Association (LISA), dan Getis-Ord-Gi*.

1. Global Moran's I

Global Moran's I merupakan statistik yang digunakan untuk mengukur tingkat autokorelasi spasial secara keseluruhan dalam wilayah penelitian. Statistik ini diperkenalkan oleh Moran (1950) untuk mempelajari hubungan spasial antarobservasi.

$$I = \frac{n}{S_0} \frac{\sum_{i=1}^{n} \sum_{j=1}^{n} w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_{i=1}^{n} (x_i - \bar{x})^2} \qquad (2.4)$$

Keterangan:

- I adalah nilai Global Moran's I
- n adalah jumlah unit pengamatan
- x_i dan x_j adalah nilai variabel di lokasi i dan j
- $\bar{x}$ merupakan rata-rata
- w_{ij} adalah bobot spasial
- $S_0 = \sum_i \sum_j w_{ij}$ merupakan jumlah seluruh bobot spasial.

Nilai Moran's I yang positif menunjukkan kecenderungan pengelompokan nilai serupa, sedangkan nilai negatif menunjukkan kecenderungan bertetangganya nilai yang berbeda. Nilai yang mendekati nol mengindikasikan hubungan spasial yang relatif lemah, tetapi tidak dengan sendirinya membuktikan bahwa distribusinya acak.

2. Local Indicators of Spatial Association (LISA)

Local Indicators of Spatial Association (LISA) merupakan kelompok statistik yang digunakan untuk mengidentifikasi autokorelasi spasial pada lokasi tertentu. Anselin (1995) memperkenalkan pendekatan ini untuk melengkapi statistik global dengan mengukur kontribusi masing-masing lokasi terhadap pola hubungan spasial.

Salah satu bentuk LISA yang banyak digunakan adalah *Local Moran's I*. Statistik ini memungkinkan identifikasi wilayah dengan nilai yang mirip dengan tetangganya maupun wilayah yang memiliki nilai berbeda dari lingkungan sekitarnya.

$$I_i = \frac{x_i - \bar{x}}{m_2} \sum_{j=1}^{n} w_{ij} \left(x_j - \bar{x}\right) \qquad (2.5)$$

$$m_2 = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^2$$

Keterangan:

- I_i merupakan statistik lokal untuk lokasi ke-i
- m_2 merupakan ukuran keragaman nilai berdasarkan rata-rata kuadrat deviasi.

Melalui Local Moran's I, pola hubungan spasial umumnya dikelompokkan menjadi empat kategori utama.

Tabel 2.1 Kategori LISA

Kategori	**Karakteristik**	**Interpretasi**
High–High (HH)	Nilai tinggi dikelilingi nilai tinggi	Klaster nilai tinggi
Low–Low (LL)	Nilai rendah dikelilingi nilai rendah	Klaster nilai rendah

Kategori	Karakteristik	Interpretasi
High–Low (HL)	Nilai tinggi dikelilingi nilai rendah	*Outlier* spasial
Low–High (LH)	Nilai rendah dikelilingi nilai tinggi	*Outlier* spasial

Kategori tersebut ditentukan berdasarkan posisi nilai pengamatan terhadap rata-rata dan nilai rata-rata tertimbang spasial di sekitarnya. Sebagai contoh, wilayah dengan jumlah deteksi kebakaran tinggi yang berdekatan dengan wilayah lain yang juga memiliki jumlah deteksi tinggi dapat termasuk kategori High–High. Sebaliknya, suatu lokasi dengan jumlah deteksi tinggi tetapi dikelilingi lokasi bernilai rendah dapat termasuk High–Low. Dalam LISA, istilah tersebut menunjukkan *outlier* statistik spasial.

Keunggulan LISA terletak pada kemampuannya memperlihatkan variasi lokal yang tidak terlihat melalui statistik global. Dua wilayah penelitian dapat menghasilkan nilai Global Moran's I yang hampir sama, tetapi memiliki lokasi dan karakteristik klaster lokal yang berbeda.

3. Getis-Ord-Gi*

Getis-Ord Gi* merupakan statistik spasial lokal yang digunakan untuk mengidentifikasi pengelompokan nilai tinggi (*hotspots*) dan nilai rendah (*coldspots*) secara signifikan. Statistik ini berkaitan dengan pendekatan yang dikembangkan oleh Getis & Ord (1992), yang menggunakan hubungan spasial untuk mengevaluasi konsentrasi nilai pada suatu lokasi dan lingkungan sekitarnya.

Berbeda dengan Local Moran's I yang dapat mengidentifikasi klaster dan *outlier*, Getis-Ord Gi* secara khusus menilai konsentrasi nilai tinggi atau rendah dalam suatu lingkungan spasial. Statistik ini membandingkan jumlah nilai tertimbang pada lokasi tertentu dengan nilai yang diharapkan berdasarkan seluruh wilayah penelitian.

Hasil Getis-Ord Gi* berupa skor-z yang dapat digunakan untuk menginterpretasikan pola pengelompokan. Skor-z positif yang besar dan signifikan menunjukkan konsentrasi nilai tinggi, sedangkan skor-z negatif yang besar secara absolut dan signifikan menunjukkan konsentrasi nilai rendah. Skor-z yang mendekati nol tidak memberikan bukti kuat adanya konsentrasi nilai tinggi atau rendah.

2.4 Bahasa Pemrograman R

R merupakan bahasa pemrograman sekaligus Integrated Development Environment (IDE) yang dikembangkan untuk analisis statistik, pengolahan data, dan visualisasi. R bersifat *open source*, sehingga dapat digunakan dan dikembangkan secara bebas oleh peneliti maupun praktisi. Menurut R Project, R mendukung berbagai metode analisis, termasuk regresi linear, pengujian statistik, klasifikasi, serta pengembangan grafik (R Project, t.t.).

Salah satu keunggulan R adalah ketersediaan berbagai paket yang dapat digunakan untuk analisis data geospasial. Paket sf menyediakan dukungan untuk pengolahan data vektor berupa titik, garis, dan poligon dengan menggunakan konsep *simple features*. Pebesma (2018)

menjelaskan bahwa struktur tersebut memungkinkan data spasial dikelola sekaligus diintegrasikan dengan analisis statistik dalam lingkungan R. Selain itu, paket terra menyediakan fungsi pengolahan data raster dan vektor, termasuk operasi perhitungan raster, perubahan resolusi, serta ekstraksi nilai berdasarkan wilayah tertentu. Kemampuan ini relevan untuk pengolahan citra satelit Sentinel-2, terutama dalam perhitungan indeks spektral seperti NDVI dan NBR.

Penggunaan R memungkinkan tahapan pengolahan data, perhitungan statistik, serta visualisasi dilakukan melalui skrip yang terdokumentasi. Dengan demikian, setiap proses analisis dapat diperiksa, diperbaiki, dan dijalankan kembali menggunakan data maupun parameter yang sama. Karakteristik ini mendukung keterulangan penelitian (*reproducibility*), terutama ketika analisis melibatkan data satelit multitemporal dan sejumlah metode statistik.

2.5 Indeks Spektral

Indeks spektral merupakan hasil perhitungan matematis yang mengombinasikan nilai reflektansi dari dua atau lebih kanal spektral untuk menonjolkan karakteristik tertentu pada permukaan bumi. Indeks ini banyak digunakan dalam penginderaan jauh karena dapat membantu membedakan kondisi vegetasi, air, tanah, dan perubahan tutupan lahan berdasarkan respons spektralnya. Dalam penelitian ini akan dibahas mengenai NDVI dan NBR.

2.5.1 Normalized Difference Vegetation Index (NDVI)

NDVI merupakan indeks vegetasi yang digunakan untuk menggambarkan tingkat kehijauan vegetasi berdasarkan perbedaan reflektansi kanal merah dan inframerah dekat. Dasar pendekatan ini berkaitan dengan karakteristik vegetasi sehat yang menyerap sebagian besar energi merah dan memantulkan energi inframerah dekat. Tucker (1979) menunjukkan bahwa kombinasi kanal merah dan inframerah dapat digunakan untuk mempelajari karakteristik vegetasi.

$$NDVI = \frac{NIR - Red}{NIR + Red} \qquad (2.6)$$

Pada Sentinel-2, kanal B8 digunakan sebagai NIR dan B4 sebagai kanal merah. Nilai NDVI berada dalam rentang teoritis -1 hingga +1. Nilai positif yang relatif tinggi umumnya menunjukkan vegetasi yang lebih hijau dan aktif secara fotosintesis, sedangkan nilai rendah dapat berkaitan dengan vegetasi jarang, tanah terbuka, atau permukaan yang tidak didominasi vegetasi. Nilai negatif sering ditemukan pada badan air atau objek lain dengan karakteristik reflektansi tertentu.

2.5.2 Normalized Burn Ratio (NBR)

NBR merupakan indeks spektral yang dirancang untuk menonjolkan perubahan karakteristik permukaan yang berkaitan dengan kebakaran, khususnya melalui perbedaan respons antara kanal NIR dan SWIR. Vegetasi sehat cenderung memiliki reflektansi NIR yang relatif tinggi dan reflektansi SWIR lebih rendah, sedangkan vegetasi yang rusak atau mengering dapat memperlihatkan perubahan pada kedua kanal tersebut.

Menurut USGS, NBR dapat digunakan untuk membantu mengidentifikasi area yang mengalami perubahan akibat kebakaran serta mendukung penilaian tingkat dampak kebakaran terhadap vegetasi.

$$NBR = \frac{NIR - SWIR}{NIR + SWIR} \qquad (2.7)$$

Pada Sentinel-2, NBR umumnya dihitung menggunakan kanal B8 sebagai NIR dan B12 sebagai SWIR. Karena kanal B8 memiliki resolusi 10 meter dan B12 memiliki resolusi 20 meter, penyamaan ukuran piksel perlu dilakukan sebelum perhitungan. Proses tersebut tidak menambah detail informasi asli dari kanal beresolusi lebih kasar.

Nilai NBR yang relatif tinggi umumnya berkaitan dengan vegetasi sehat, sementara nilai yang lebih rendah dapat menunjukkan vegetasi rusak, lahan terbuka, atau permukaan yang mengalami perubahan akibat kebakaran.

BAB III
METODOLOGI

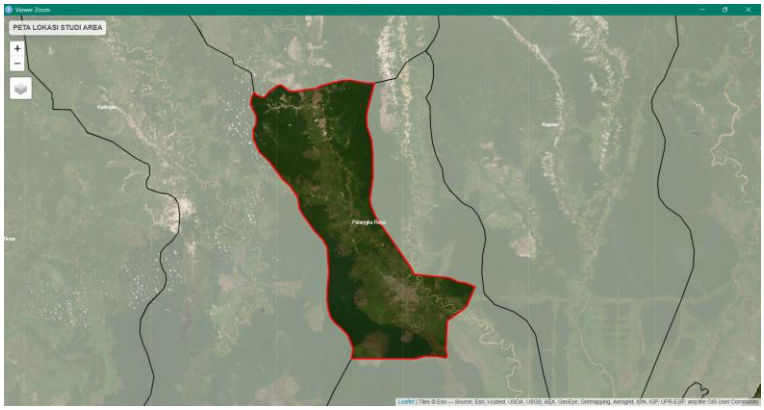
3.1 Lokasi Penelitian

Penelitian ini dilaksanakan di Kota Palangka Raya, Provinsi Kalimantan Tengah. Secara geografis, Kota Palangka Raya terletak pada koordinat 113°30'–114°04' Bujur Timur dan 1°30'–2°30' Lintang Selatan. Wilayah ini berbatasan dengan Kabupaten Gunung Mas di sebelah utara dan timur, Kabupaten Pulang Pisau di sebelah selatan, serta Kabupaten Katingan di sebelah barat. Secara administratif, Kota Palangka Raya terdiri atas lima kecamatan, yaitu Pahandut, Jekan Raya, Sabangau, Bukit Batu, dan Rakumpit, dengan luas wilayah mencapai 2.853,12 km² (Badan Pusat Statistik Kota Palangka Raya, 2026).



Gambar 3.1 Kabupaten dan Kota di Kalimantan Tengah

Pemilihan lokasi penelitian dilakukan secara bertahap, dimulai dari penentuan provinsi yang memiliki tingkat kerawanan kebakaran hutan dan lahan (karhutla) yang tinggi, kemudian dilanjutkan dengan pemilihan wilayah kabupaten/kota yang dinilai sesuai dengan tujuan penelitian. Provinsi Kalimantan Tengah dipilih berdasarkan tingginya aktivitas titik panas (*hotspot*) yang teridentifikasi melalui pengamatan penginderaan jauh. Berdasarkan laporan Pantau Gambut yang dipublikasikan pada 3 September 2026, jumlah titik panas di wilayah Kesatuan Hidrologis Gambut (KHG) Kalimantan Tengah mengalami peningkatan sebesar 2.494%, dari 2.821 titik panas pada Juli menjadi 73.183 titik panas pada Agustus 2026 (Pantau Gambut, 2026). Peningkatan tersebut menunjukkan adanya eskalasi jumlah titik panas yang perlu mendapat perhatian, khususnya berkaitan dengan potensi kejadian karhutla.



Gambar 3.2 Lokasi penelitian yang dipilih

Setelah penentuan provinsi, Kota Palangka Raya dipilih dengan mempertimbangkan luas administratif serta riwayat kejadian karhutla. Salah satu pertimbangan utama adalah tingginya intensitas kebakaran yang pernah terjadi di kota tersebut. Berdasarkan informasi Pemerintah Kota Palangka Raya (2025), luas wilayah yang terdampak karhutla pada tahun 2015 mencapai sekitar 13.399 hektare dan meningkat menjadi sekitar 16.289 hektare pada tahun 2019. Kejadian kebakaran juga kembali meningkat pada tahun 2023, dengan luas area terbakar mencapai 3.892,15 hektare, sebelum mengalami penurunan menjadi 26,08 hektare pada tahun 2024 (Dinas Lingkungan Hidup Kota Palangka Raya, 2025). Variasi luas kebakaran antartahun tersebut memperlihatkan bahwa karhutla merupakan permasalahan lingkungan yang bersifat berulang, tetapi memiliki intensitas yang berubah dari waktu ke waktu. Oleh karena itu, Kota Palangka Raya dinilai relevan untuk dijadikan wilayah penelitian dalam mengidentifikasi karakteristik dan pola persebaran spasial kejadian karhutla.

Pertimbangan berikutnya berkaitan dengan luas dan batas wilayah administratif. Berdasarkan data BPS Kota Palangka Raya (2026), luas wilayah kota mencapai 2.853,12 km² dengan distribusi luas yang berbeda pada setiap kecamatan. Luas wilayah tersebut memberikan cakupan spasial yang memadai untuk mengamati variasi karakteristik lahan, sekaligus memungkinkan analisis dilakukan secara lebih terfokus dibandingkan dengan cakupan seluruh Provinsi Kalimantan Tengah. Selain itu, luas yang relatif kecil dibandingkan dengan kabupaten/kota lain yang ada di Kalimantan Tengah menjadi keuntungan dari segi pemrosesan data. Karena pengolahan yang dilakukan masih bersifat lokal pada perangkat, luas wilayah ini mempercepat proses pengolahan data.

3.2 Bahan dan Peralatan

3.2.1 Bahan

Data yang diperlukan dalam penelitian ini yakni sebagai berikut:

1. Data Batas Administrasi Kota Palangka Raya tingkat kota dan kelurahan yang diperoleh dari Database of Global Administrative Areas (GADM) versi 4.1 melalui tautan https://gadm.org/data.html
2. Data titik panas (*hotspot*) yang diperoleh dari tiga misi satelit VIIRS (Suomi NPP, NOAA 20, dan NOAA 21) Level-2 dengan resolusi spasial 375 meter dan resolusi temporal 0.5 hari dari tanggal 1 Agustus 2026 hingga 31 Agustus 2026. Data diperoleh dari Fire Information

for Resource Management System (FIRMS) milik NASA yang dapat diakses melalui https://firms.modaps.eosdis.nasa.gov/download/

3. Data jaringan jalan, jaringan kanal, serta jaringan sungai di Kota Palangka Raya dengan skala 1:25.000 yang diperoleh dari Badan Informasi Geospasial melalui https://tanahair.indonesia.go.id/portal-web/
4. Data citra satelit Sentinel-2 dengan rentang waktu 1 Juli 2026 hingga 30 September 2026 yang disediakan oleh ESA dan diakses melalui katalog Google Earth Engine (GEE).

3.2.2 Peralatan

Adapun peralatan yang digunakan dalam penelitian tugas akhir ini adalah:

1. Perangkat Keras (*Hardware*)
   Laptop Lenovo Ideapad Gaming 3, dengan spesifikasi sebagai berikut:

Tabel 3.1 Spesifikasi perangkat keras yang digunakan

Nama Perangkat	Lenovo IdeaPad Gaming 3 15IHU6
Processor	11th Gen Intel(R) Core(TM) i5-11300H @ 3.10GHz 3.11 GHz
RAM	8 GB
System Type	64-bit operating system, x64-based processor
Edisi Windows	Windows 11 Home Single Language
Penyimpanan	477 GB (internal)
GPU	Intel® Iris® Xe Graphics 4GB NVIDIA GeForce GTX 1650 8GB

2. Perangkat Lunak (*Software*)
   a. Bahasa Pemrograman R (versi 4.6)
   b. Integrated Development Environment (IDE) R yakni RStudio
   c. Microsoft 365

3.3 Metode Penelitian

3.3.1 Tahapan Pelaksanaan Penelitian

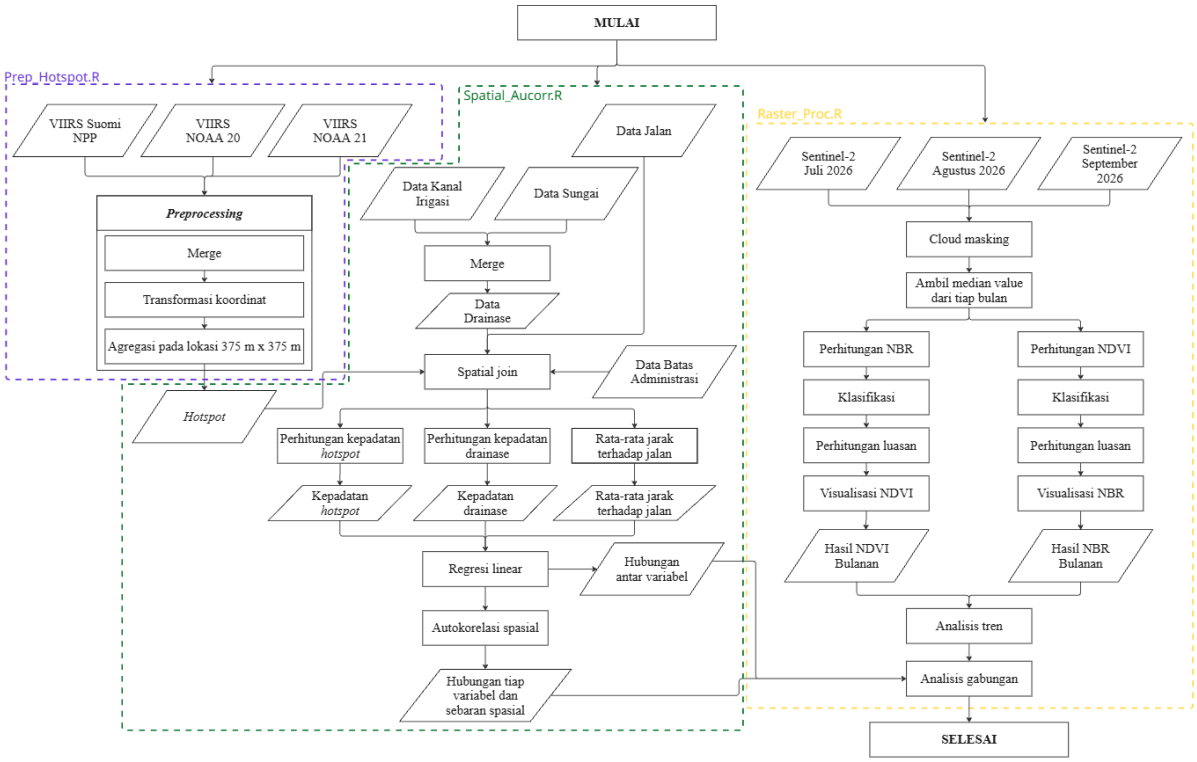
Pelaksanaan penelitian diawali dengan tahap identifikasi masalah yang melatarbelakangi penelitian, khususnya terkait fenomena kebakaran hutan dan lahan di Kota Palangka Raya, Provinsi Kalimantan Tengah. Pada tahap ini dilakukan perumusan masalah, penentuan tujuan, serta batasan penelitian sebagai dasar dalam pelaksanaan penelitian. Selanjutnya, dilakukan studi literatur yang mencakup kajian penelitian terdahulu, konsep penginderaan jauh, pemanfaatan indeks spektral, serta metode analisis statistik yang relevan dengan penelitian.

Tahap berikutnya adalah pengumpulan data yang diperlukan, meliputi data citra satelit Sentinel-2, data titik panas VIIRS, serta data pendukung lainnya. Data yang telah diperoleh kemudian melalui tahapan *preprocessing* dan pengolahan untuk menghasilkan informasi yang dibutuhkan dalam penelitian. Hasil pengolahan selanjutnya dianalisis menggunakan pendekatan statistik, meliputi analisis regresi linear dan autokorelasi spasial, untuk mengidentifikasi hubungan antarvariabel serta pola persebaran spasial yang terbentuk.

Berdasarkan hasil analisis tersebut, dilakukan interpretasi dan penarikan kesimpulan untuk menjawab rumusan masalah dan tujuan penelitian yang telah ditetapkan. Seluruh tahapan dan hasil penelitian kemudian disusun secara sistematis dalam bentuk laporan tugas sesuai dengan ketentuan penulisan yang berlaku.

3.3.2 Tahapan Pengolahan Data

Pengolahan data pada penelitian ini dilakukan menggunakan bahasa pemrograman R yang terbagi menjadi tiga tahapan utama, yaitu persiapan data titik panas (Prep_Hotspot.R), pengolahan dan analisis statistik spasial (Spatial_Aucorr.R), serta pengolahan data raster (Raster_Proc.R). Ketiga tahapan tersebut dilakukan untuk memperoleh informasi mengenai persebaran titik panas, hubungan antara titik panas dengan faktor lingkungan, serta perubahan kondisi vegetasi dan lahan di Kota Palangka Raya selama periode penelitian. Tahap pengolahan data dapat dilihat pada Gambar 3.3 berikut:



Gambar 3.3 Tahap pengolahan data

1. Persiapan Data Titik Panas (Prep_Hotspot.R)

Tahap pertama merupakan persiapan data titik panas yang diperoleh dari sensor VIIRS pada satelit Suomi NPP, NOAA-20, dan NOAA-21. Ketiga data tersebut digabungkan menjadi satu dataset, kemudian dilakukan transformasi sistem koordinat ke WGS 84/UTM Zona 49S (EPSG:32749) agar sesuai dengan wilayah penelitian. Selanjutnya, dilakukan agregasi titik panas menggunakan grid berukuran 375 × 375 meter berdasarkan tanggal pengamatan untuk mengurangi duplikasi titik panas yang terdeteksi oleh beberapa satelit pada lokasi dan waktu pengamatan yang berdekatan. Pada setiap grid dan tanggal

pengamatan, dipertahankan nilai brightness maksimum sebagai representasi deteksi titik panas. Hasil pengolahan berupa data titik panas yang telah diagregasi dan digunakan sebagai masukan pada tahap analisis spasial berikutnya.

2. Pengolahan dan Analisis Statistik Spasial (Spatial_Aucorr.R)

   Tahap kedua dilakukan untuk mengidentifikasi hubungan antara persebaran titik panas dengan karakteristik spasial wilayah penelitian. Data yang digunakan meliputi titik panas hasil pengolahan sebelumnya, jaringan jalan, sungai, saluran irigasi, serta batas administrasi Kota Palangka Raya. Data sungai dan saluran irigasi digabungkan menjadi jaringan drainase, kemudian dilakukan penggabungan spasial (spatial join) dan perhitungan variabel pada satuan analisis yang dipilih. Pada penelitian ini, khusus pada bagian analisis statistik spasial akna digunakan 2 pendekatan satuan area yakni batas kelurahan dan grid berukuran 1 km × 1 km. Variabel yang dihitung meliputi kepadatan titik panas, kepadatan drainase, dan rata-rata jarak terhadap jalan.

   Ketiga variabel tersebut selanjutnya dianalisis menggunakan regresi linear sederhana dan berganda untuk mengetahui hubungan antara kepadatan titik panas dengan kepadatan drainase serta jarak terhadap jalan. Analisis dilanjutkan dengan pengujian autokorelasi spasial menggunakan Global Moran's I untuk mengetahui kecenderungan pengelompokan spasial secara keseluruhan, Local Indicators of Spatial Association (LISA) untuk mengidentifikasi pola pengelompokan lokal, serta Getis-Ord Gi* untuk menentukan wilayah dengan konsentrasi nilai tinggi (*hotspot*) dan rendah (*coldspot*) secara statistik. Hasil pengolahan disajikan dalam bentuk peta tematik, grafik, dan tabel sebagai dasar interpretasi hubungan antarvariabel serta karakteristik persebaran spasialnya.

3. Pengolahan Data Raster (Raster_Proc.R)

   Tahap ketiga merupakan pengolahan data citra satelit Sentinel-2 untuk mengidentifikasi kondisi vegetasi dan permukaan lahan di Kota Palangka Raya selama Juli hingga September 2026. Pengolahan diawali dengan penyaringan piksel yang terpengaruh awan (cloud masking) berdasarkan Scene Classification Layer (SCL), kemudian dilakukan penyusunan komposit bulanan menggunakan nilai median dari citra yang tersedia. Selanjutnya, dilakukan perhitungan Normalized Difference Vegetation Index (NDVI) untuk menggambarkan kondisi dan kerapatan vegetasi serta Normalized Burn Ratio (NBR) untuk mengamati kondisi vegetasi dan indikasi gangguan pada permukaan lahan.

   Hasil perhitungan kedua indeks kemudian dipotong berdasarkan batas administrasi Kota Palangka Raya dan diklasifikasikan ke dalam empat kategori berdasarkan rentang nilai yang telah ditentukan. Setiap kategori dihitung luasannya berdasarkan jumlah piksel untuk memperoleh distribusi kondisi vegetasi dan lahan pada masing-masing bulan. Hasil pengolahan divisualisasikan dalam bentuk peta sebaran indeks spektral dan grafik perubahan luasan kategori selama periode pengamatan. Selanjutnya, dilakukan analisis tren untuk mengetahui perubahan kondisi vegetasi dan lahan secara temporal. Hasil analisis raster kemudian diinterpretasikan bersama hasil analisis statistik spasial untuk memberikan

gambaran mengenai hubungan antara persebaran titik panas, karakteristik lingkungan, dan perubahan kondisi vegetasi di wilayah penelitian.

3.3.3 Langkah Pengerjaan

Berikut ini merupakan langkah-langkah pengerjaan dari pengolahan yang dilakukan. Langkah pengerjaan dibagi menjadi 3 bagian/file. Beberapa bagian kode dipotong untuk menghemat halaman, versi lengkap dari kode dapat dilihat pada lampiran maupun repositori GitHub berikut: https://github.com/AntaraAntariksa/PDS-midterm-2026.git

1. Persiapan Data Titik Panas (Prep_Hotspot.R)
   a) Load library dan set workspace

```
library(sf)
library(dplyr)

#atur direktori
workdir <- ("C:/an/ETS/")
setwd(workdir)
getwd() #cek
```

   b) Baca data dan merge

```
snpp <- st_read("fire_nrt_SV-C2_825463.shp")
n20 <- st_read("fire_nrt_J1V-C2_825461.shp")
n21 <- st_read("fire_nrt_J2V-C2_825462.shp")

# merge data jadi satu (kolom persis)
viirs_gabungan <- bind_rows(snpp, n20, n21)
```

   c) Transformasi koordinat dari WGS84 ke UTM49s

```
viirs_utm <- st_transform(viirs_gabungan, crs = 32749)
```

   d) Buat grid luas 375 m × 375 m sesuai resolusi spasial untuk agregasi nantinya

```
grid_375m <- st_make_grid(viirs_utm, cellsize = 375, square = TRUE) %>%
  st_sf(grid_id = 1:length(.)) # jadi objek sf dan beri kolom ID berurutan
```

   e) Spatial join antara titik panas dan grid

```
titik_grid <- st_join(viirs_utm, grid_375m, join = st_intersects)
```

   f) Agregasi antara kedua data (dalam 1 kotak grid, hanya dipilih 1 titik yang ada pada 1 waktu dengan mempertahankan metadata *brightness* tertinggi)

```
titik_bersih <- titik_grid %>%
  group_by(grid_id, ACQ_DATE) %>%
  summarise(
    BRIGHTNESS = max(BRIGHTNESS, na.rm = TRUE),
    CONFIDENCE = first(CONFIDENCE),
    SATELLITE = paste(unique(SATELLITE), collapse = ","),
    .groups = "drop"
  ) %>%
  st_centroid()
```

g) Hitung jumlah titik lalu export untuk digunakan di tahap selanjutnya

```
total_titik <- nrow(titik_bersih)
print(paste("Total titik api bersih (tanpa duplikat):", total_titik))

st_write(titik_bersih, "hotspot_kalteng_bersih.shp", append = FALSE)
```

2. Pengolahan dan Analisis Statistik Spasial (Spatial_Aucorr.R)

a) Load library dan set working directory

```
library(sf)
library(tmap)
library(terra)
library(dplyr)
library(spData)
library(spdep)
library(ggplot2)
library(patchwork)
library(exactextractr)

#atur direktori
workdir <- ("C:/an/ETS/")
setwd(workdir)
getwd() #cek
```

b) Memuat dan transformasi koordinat data spasial jalan, sungai, irigasi, batas administrasi, dan titik panas ke UTM 49S. Plot untuk memastikan data benar

```
desa <- st_read("KotaPalangkaraya/Desa_Palangkaraya.shp") |> st_transform(32749)
hotspot <- st_read("hotspot_kalteng_bersih.shp") |> st_transform(32749)
plot(st_geometry(desa))
plot(st_geometry(hotspot), add = TRUE)

gdb_path <- "KotaPalangkaraya/RBI25K_KOTA PALANGKARAYA_KUGI50.gdb"
st_layers(gdb_path)

jalan   <- st_read(dsn = gdb_path, layer = "JALAN_LN_25K") |>
  st_transform(32749)
sungai  <- st_read(dsn = gdb_path, layer = "SUNGAI_LN_25K") |>
  st_transform(32749)
irigasi <- st_read(dsn = gdb_path, layer = "IRIGASI_LN_25K") |>
  st_transform(32749)
```

c) Merge data sungai dan kanal irigasi menjadi data drainase, lalu plot untuk memastikan data benar

```
sungai_clean <- st_sf(
  tipe = "Sungai",
  geometry = st_geometry(sungai))
irigasi_clean <- st_sf(
  tipe = "Irigasi",
  geometry = st_geometry(irigasi))
drainase <- bind_rows(sungai_clean, irigasi_clean)

# cek plot
plot(st_geometry(drainase), col = "blue", add = TRUE)
plot(st_geometry(jalan), col = "darkgreen", add = TRUE)
```

d) Hitung jarak terhadap jalan menggunakan Euclidean Distance dengan hasil berupa raster lalu diplot. Hasil ini akan dirata-rata per satuan analisis untuk mengetahui nilai rata-rata jarak terhadap jalan di tiap unit analisis.

```
temp_raster  <- rast(ext(desa), resolution = 30, crs = crs(desa))
jalan_vect   <- vect(jalan)
jalan_raster <- rasterize(jalan_vect, temp_raster, field = 1)
dist_raster  <- distance(jalan_raster)
plot(dist_raster)
```

e) Menentukan satuan analisis (wilayah administrative kelurahan/desa atau grid 1 x 1 kilometer)

```
pilihan_batas <- "grid" #desa atau grid 1x1 km

if (pilihan_batas == "desa") {
  input <- desa |>
    mutate(
      id_unit  = as.character(NAME_3), #NAME_3 untuk tingkat kecamatan
      luas_km2 = as.numeric(st_area(geometry)) / 1e6)
  style <- "S" #buat input nb2listw

} else if (pilihan_batas == "grid") {
  grid_raw <- st_make_grid(
    desa,
    cellsize = c(1000, 1000),
    square   = TRUE)
  input <- st_sf(geometry = grid_raw) |>
    st_filter(desa) |>
    mutate(
      id_unit  = paste0("GRID_", row_number()),
      luas_km2 = 1)
  style <- "W" #buat input nb2listw

} else {
  stop("Pilihan tidak valid! Pilih 'desa' atau 'grid'.")
}
```

f) Menghitung kepadatan titik panas, kepadatan drainase, dan jarak rata-rata terhadap jalan

```
# HOTSPOT DENSITY
input$hotspot_count <- lengths(st_intersects(input, hotspot))
input <- input |>
  mutate(hotspot_density = hotspot_count / luas_km2)

# DRAINAGE DENSITY
drainase_intersect <- st_intersection(drainase, input) |>
  mutate(panjang_kanal_km = as.numeric(st_length(geometry)) / 1000)

drainase_summary <- drainase_intersect |>
  st_drop_geometry() |>
  group_by(id_unit) |>
  summarise(tot_panjang_kanal = sum(panjang_kanal_km, na.rm = TRUE))

input <- input |>
  left_join(drainase_summary, by = "id_unit") |>
  mutate(
    tot_panjang_kanal = ifelse(is.na(tot_panjang_kanal), 0, tot_panjang_kanal),
    drain_density     = tot_panjang_kanal / luas_km2)

# RATA-RATA JARAK TERHADAP JALAN
input$mean_dist_road_m <- exact_extract(dist_raster, input, 'mean')
```

```
# CEK OUTPUT AKHIR
head(input |> select(id_unit, hotspot_density, drain_density, mean_dist_road_m))
```

g) Melakukan regresi linear sederhana dan berganda serta membuat grafik dan peta variabel

```
clean <- input %>% st_drop_geometry()

# 3.1 Exploratory Data Analysis
eda_summary <- clean %>%
  summarise(
    across(
      c(hotspot_density, drain_density, mean_dist_road_m),
      list(
        mean   = ~mean(.x, na.rm = TRUE),
        sd     = ~sd(.x, na.rm = TRUE),
        median = ~median(.x, na.rm = TRUE),
        min    = ~min(.x, na.rm = TRUE),
        max    = ~max(.x, na.rm = TRUE)
      ),
      .names = "{.col}_{.fn}"
    )
  )
t(eda_summary)

# 3.2 Regresi Linear (Bivariat)
# Densitas Drainase -> Hotspot
reg_drain <- lm(hotspot_density ~ drain_density, data = clean)
summary(reg_drain)

# Jarak ke Jalan -> Hotspot
reg_road <- lm(hotspot_density ~ mean_dist_road_m, data = clean)
summary(reg_road)

# 3.3 Regresi Linear Berganda
ols_model <- lm(hotspot_density ~ drain_density + mean_dist_road_m, data = clean)
summary(ols_model)

r2_drain  <- paste0("R² = ", round(summary(reg_drain)$r.squared, 4))
p1 <- ggplot(clean, aes(x = drain_density, y = hotspot_density)) +
  geom_point(color = "red", size = 2.5, alpha = 0.7) +
  geom_smooth(method = "lm", color = "black", se = FALSE) +
  annotate("text", x = 0.05, y = 9, label = r2_drain, hjust = 0, size = 3.8) +
  labs(
    title = "Scatterplot Kanal vs Titik Panas",
    x = "Kepadatan Drainase (km/km²)",
    y = "Kepadatan Titik Panas"

….

    point_data         = clean_centroids,
    var_name           = "mean_dist_road_m",
    point_color        = "purple",
    legend_title_point = "Jarak Jalan (m)",
    title              = "Peta Perbandingan Titik Panas dan Jarak ke Jalan",
  )
map_road
```

h) Membentuk matriks bobot spasial berdasarkan Queen contiguity

```
nb <- poly2nb(input, queen = TRUE)
lw <- nb2listw(nb, style = style, zero.policy = TRUE)
summary(nb)
```

i) Menghitung Global Moran's I dan menampilkan Moran scatterplot

```
globalMoran <- function(variabel, warna = "steelblue", main_title = NULL) {
  if (is.null(main_title)) main_title <- paste("Moran Plot - Variabel", variabel)
  x <- input[[variabel]]
  moran <- moran.test(x = x,
                      listw = lw,
                      alternative = 'greater',
                      zero.policy = TRUE)
  print(moran)
  moran.plot(
    x = x,
    listw = lw,
    pch = 16,
    col = warna,
    main = main_title,
    zero.policy = TRUE,
    xlab = variabel,
    ylab = paste("spatially lagged", variabel))
  res <- data.frame(
    Variabel     = variabel,
    Moran_I      = round(as.numeric(moran$estimate[["Moran I statistic"]]), 4),
    Expectation  = round(as.numeric(moran$estimate[["Expectation"]]), 4),
    P_Value      = round(moran$p.value, 5),
    Signifikan   = ifelse(moran$p.value <= 0.05, "Ya", "Tidak"))
  return(res)
}
```

j) Menghitung Local Moran's I (LISA) dan memetakan pola klaster lokal

```
lisaCalc <- function(variabel, alpha = 0.05, alternative = "two.sided", title = NULL) {
  if (is.null(title)) title <- paste("Peta LISA - Variabel", variabel)
  x <- input[[variabel]]
  z_x <- as.numeric(scale(x))
  lag_z_x <- lag.listw(lw, z_x, zero.policy = TRUE)
  local_m <- localmoran(z_x, lw, alternative = alternative, zero.policy = TRUE)
  data_result <- input |>
    mutate(
      z_val     = z_x,
      lag_z_val = lag_z_x,
      p_val     = local_m[, 5],
      quadrant = case_when(
        z_val >= 0 & lag_z_val >= 0 ~ "High-High",
        z_val < 0  & lag_z_val < 0  ~ "Low-Low",
        z_val >= 0 & lag_z_val < 0  ~ "High-Low",
        z_val < 0  & lag_z_val >= 0 ~ "Low-High"),
      quadrant_sig = ifelse(p_val <= alpha, quadrant, "Not Significant"))
  peta <- tm_shape(data_result) +
    tm_polygons(
      fill = "quadrant_sig",
      fill.scale = tm_scale_categorical(
        values = c(
          "High-High"       = "#d7191c",
          "Low-Low"         = "#2b83ba",
          "High-Low"        = "#fdae61",
          "Low-High"        = "#abdda4",
          "Not Significant" = "#e0e0e0"
        ),
        levels = c("High-High", "Low-Low", "High-Low", "Low-High", "Not Significant")
      ),
      fill.legend = tm_legend(
        title = "Kategori Klaster",
        position = tm_pos_out("right", "center")
      )
    ) +
```

```
    tm_grid(alpha = 0.2) + # Grid default
    tm_compass(position = tm_pos_in("right", "top")) +
    tm_scalebar(position = tm_pos_in("left", "bottom")) +
    tm_title(
      text = title,
      size = 1.1,
      fontface = "bold",
      position = tm_pos_out("center", "top")
    ) +
    tm_layout(component.autoscale = FALSE)
  return(list(data = data_result, plot = peta))
}
```

k) Menghitung Getis-Ord Gi* untuk mengidentifikasi hotspot dan coldspot statistik

```
nb_self <- include.self(nb)
lw_gi   <- nb2listw(nb_self, style = "B", zero.policy = TRUE)

giCalc <- function(variabel) {
  x <- input[[variabel]]
  gi_results <- localG(x, lw_gi, zero.policy = TRUE)
  gi_zscore  <- as.numeric(gi_results)
  data_res <- input |>
    mutate(
…
      ),
      gi_category = factor(gi_category, levels = c("Hotspot 99%", "Hotspot 95%", "Hotspot
90%",
                                                   "Not Significant",
                                                   "Coldspot 90%", "Coldspot 95%", "Coldspot
99%"))
    )
  peta <- tm_shape(data_res) +
    tm_polygons(
      fill = "gi_category",
      fill.scale = tm_scale_categorical(
        values = c(
          …
        ),
        levels = c(
          "Hotspot 99%", "Hotspot 95%", "Hotspot 90%",
          "Not Significant",
          "Coldspot 90%", "Coldspot 95%", "Coldspot 99%"
        )
      ),
      fill.legend = tm_legend(
        title = "Tingkat Kepercayaan",
        position = tm_pos_out("right", "center")
      ),
      col = NA
    ) +
    tm_grid(alpha = 0.2) +
    tm_compass(position = tm_pos_in("right", "top")) +
    tm_scalebar(position = tm_pos_in("left", "bottom")) +
    tm_title(
      text = paste("Getis-Ord Gi* - Variabel", variabel),
      size = 1.1,
      fontface = "bold",
      position = tm_pos_out("center", "top")
    ) +
    tm_layout(component.autoscale = FALSE)

  list(data = data_res, plot = peta)
}
```

l) Menjalankan seluruh analisis per variabel, menyusun ringkasan, dan mengekspor hasil

```
list_summary_master  <- list()
list_ranking_hotspot <- list()
list_plot_lisa       <- list()
list_plot_gi         <- list()

for (v in var_list) {
…
}

tabel_master_final <- bind_rows(list_summary_master)
tabel_ranking_hotspot <- bind_rows(list_ranking_hotspot)

####EXPORT
folder_tujuan <- "plot_grid"

if (!dir.exists(folder_tujuan)) {
  dir.create(folder_tujuan)
}

for (v in var_list) {
  tmap_save(list_plot_lisa[[v]], file.path(folder_tujuan, paste0("LISA_", v, ".png")),
            width = 5.5, height = 5, units = "in", dpi = 100)

  tmap_save(list_plot_gi[[v]], file.path(folder_tujuan, paste0("Gi_", v, ".png")),
            width = 6.5, height = 5, units = "in", dpi = 100)
}

write.csv(tabel_master_final, file.path(folder_tujuan, "tabel_master_final.csv"), row.names =
FALSE)
write.csv(tabel_ranking_hotspot, file.path(folder_tujuan, "tabel_ranking_hotspot.csv"),
row.names = FALSE)
```

3. Pengolahan Data Raster (Raster_Proc.R)

a) Load rgee, mengatur AOI, *masking* awan, serta menghitung dan mengekspor komposit NDVI–NBR Juli–September 2026. Hasil akan diperoleh pada google drive dan diunduh secara manual untuk melanjutkan proses analisis.

```
library(rgee)
library(reticulate)

reticulate::use_python("C:/Users/Andini A/.conda/envs/rgee/python.exe",
           required = TRUE)
reticulate::py_config()
reticulate::conda_list()
ee_Authenticate()
ee_Initialize()

xmin <- 113.53
ymin <- -2.40
xmax <- 114.1
ymax <- -1.65

aoi <- ee$Geometry$BBox(xmin, ymin, xmax, ymax)

mask_s2_clouds <- function(image) {
  scl <- image$select("SCL")
  clear_pixels <- scl$neq(3)$And(scl$neq(8))$And(scl$neq(9))$And(scl$neq(10))
  return(image$updateMask(clear_pixels))
}
```

```
add_indices <- function(image) {
  ndvi <- image$normalizedDifference(c("B8", "B4"))$rename("NDVI")
  nbr  <- image$normalizedDifference(c("B8", "B12"))$rename("NBR")
  return(image$addBands(c(ndvi, nbr)))
}

s2_col <- ee$ImageCollection("COPERNICUS/S2_SR_HARMONIZED")$
  filterBounds(aoi)$
  map(mask_s2_clouds)$
  map(add_indices)

juli <- s2_col$filterDate("2026-07-01", "2026-07-31")$median()$clip(aoi)
agustus <- s2_col$filterDate("2026-08-01", "2026-08-31")$median()$clip(aoi)
september <- s2_col$filterDate("2026-09-01", "2026-09-30")$median()$clip(aoi)

monthly_list <- list(
  Jul = juli,
  Aug = agustus,
  Sep = september
)

indices <- c("NDVI", "NBR")

for (m in names(monthly_list)) {
  for (idx in indices) {
    task <- ee_image_to_drive(
      image = monthly_list[[m]]$select(idx),
      description = paste0("S2_", idx, "_Palangkaraya_", m),
      folder = "FINAL",
      scale = 10,
      region = aoi
    )
    task$start()
  }
}
ee_monitoring()
```

b) Set direktori, load library, dan batas administrasi Kota Palangka Raya

```
workdir <- ("C:/an/ETS/")
setwd(workdir)
getwd() #cek

library(terra)
library(dplyr)
library(ggplot2)
library(patchwork)

shp_pky <- vect("KotaPalangkaraya/Palangka_Raya.shp")
```

c) Menentukan kelas NDVI dan NBR, label kategori, dan palet warna visualisasi

```
m_ndvi <- matrix(c(
  -Inf, 0.30, 1,
  0.30, 0.60, 2,
  0.60, 0.78, 3,
  0.78,  Inf, 4
), ncol = 3, byrow = TRUE)

m_nbr <- matrix(c(
  -Inf, 0.05, 1,
  0.05, 0.35, 2,
  0.35, 0.60, 3,
  0.60,  Inf, 4
```

```
), ncol = 3, byrow = TRUE)

lbls_ndvi <- c("Non-Vegetasi", "Jarang", "Sedang", "Rapat")
lbls_nbr <- c("Terganggu Tinggi", "Terganggu Sedang", "Normal", "Sehat/Lembap")

cols_ndvi <- c(
  "Non-Vegetasi" = "#d7191c", # Merah Cerah
  "Jarang"       = "#fdae61", # Oranye-Kuning
  "Sedang"       = "#a6d96a", # Hijau Muda
  "Rapat"        = "#1a9641"  # Hijau Tua
)

cols_nbr <- c(
  "Terganggu Tinggi" = "#67000d", # Maroon Pekat (Bekeras/Terbakar Parah)
  "Terganggu Sedang" = "#f46d43", # Oranye Cerah
  "Normal"           = "#fee08b", # Kuning Lembut / Jerami
  "Sehat/Lembap"     = "#2b83ba"  # Biru Teal (Simbol Area Lembap/Air)
)

cols_all <- c(cols_ndvi, cols_nbr)
```

d) Mendefinisikan fungsi penghitungan luas setiap kategori raster. Fungsi get_summary() memuat raster sesuai bulan dan indeks, memotong sekaligus memberi mask batas studi, kemudian mengklasifikasikan setiap piksel. Jumlah piksel tiap kelas dihitung dan dikonversi menjadi hektare serta ribuan hektare menggunakan asumsi ukuran piksel 10 × 10 meter.

```
get_summary <- function(month, index_type, shp, path_folder = "Res_RGEE") {
  file_path <- sprintf("%s/S2_%s_Palangkaraya_%s_2026.tif", path_folder, index_type, month)
  r <- rast(file_path)
  r_cut <- crop(r, shp, mask = TRUE)
  is_ndvi <- index_type == "NDVI"
  m <- if (is_ndvi) m_ndvi else m_nbr
  lbls <- if (is_ndvi) lbls_ndvi else lbls_nbr
  r_class <- classify(r_cut, m, right = FALSE)
  freq_df <- as.data.frame(freq(r_class))
  freq_df %>%
    filter(!is.na(value)) %>%
    transmute(
      Bulan = factor(month, levels = c("Jul", "Aug", "Sep")),
      Indeks = index_type,
      Kategori = factor(lbls[value], levels = lbls),
      Piksel = count,
      Luas_ha = (count * 100) / 10000,
      Luas_ribu_ha = Luas_ha / 1000 # ribu Ha
    )
}
```

e) Mengiterasi fungsi ringkasan untuk seluruh bulan dan kedua indeks

```
param_grid <- expand.grid(
  month = c("Jul", "Aug", "Sep"),
  index_type = c("NDVI", "NBR"),
  stringsAsFactors = FALSE
)

df_summary <- bind_rows(lapply(1:nrow(param_grid), function(i) {
  get_summary(param_grid$month[i], param_grid$index_type[i], shp_pky)
}))
```

f) Mendefinisikan fungsi plot peta dan grafik luas kategori

```
plot_map_and_chart <- function(target_month, target_index, df_sum, shp, path_folder =
"Res_RGEE", sample_fact = 5) {
  file_path <- sprintf("%s/S2_%s_Palangkaraya_%s_2026.tif", path_folder, target_index,
target_month)
  r <- rast(file_path)
  r_cut <- crop(r, shp, mask = TRUE)

  is_ndvi <- target_index == "NDVI"
  m <- if (is_ndvi) m_ndvi else m_nbr
  lbls <- if (is_ndvi) lbls_ndvi else lbls_nbr
  pal <- if (is_ndvi) cols_ndvi else cols_nbr

  r_class <- classify(r_cut, m, right = FALSE)

  if (sample_fact > 1) {
    r_plot <- aggregate(r_class, fact = sample_fact, fun = "modal")
  } else {
    r_plot <- r_class
  }

  df_map <- as.data.frame(r_plot, xy = TRUE)
  names(df_map)[3] <- "Kelas_Val"

  df_map <- df_map %>%
    filter(!is.na(Kelas_Val)) %>%
    mutate(Kategori = factor(lbls[Kelas_Val], levels = lbls))

  sub_sum <- df_sum %>% filter(Indeks == target_index, Bulan == target_month)

  p_map <- ggplot(df_map, aes(x = x, y = y, fill = Kategori)) +
…
    theme(
      legend.position = "bottom",
      plot.title = element_text(face = "bold", size = 12, hjust = 0.5)
    )

  p_chart <- ggplot(sub_sum, aes(x = Kategori, y = Luas_ribu_ha, fill = Kategori)) +
…
      plot.title = element_text(face = "bold", size = 11, hjust = 0.5)
    )

  p_map + p_chart + plot_layout(widths = c(2, 1))
}
```

g) Menjalankan visualisasi tiap kombinasi bulan dan indeks

```
plot_map_and_chart("Jul", "NDVI", df_summary, shp_pky)
plot_map_and_chart("Aug", "NDVI", df_summary, shp_pky)
plot_map_and_chart("Sep", "NDVI", df_summary, shp_pky)
plot_map_and_chart("Jul", "NBR", df_summary, shp_pky)
plot_map_and_chart("Aug", "NBR", df_summary, shp_pky)
plot_map_and_chart("Sep", "NBR", df_summary, shp_pky)
```

h) Mendefinisikan fungsi grafik tren bulanan untuk NDVI dan NBR

```
build_trend_plot <- function(df_data, include_dense = TRUE) {

  if (include_dense) {
    df_ndvi <- df_data %>% filter(Indeks == "NDVI")
    df_nbr  <- df_data %>% filter(Indeks == "NBR")
    sub_title <- "Semua Kategori Tutupan & Kondisi Lahan"
```

```
  } else {
    df_ndvi <- df_data %>% filter(Indeks == "NDVI", Kategori != "Rapat")
    df_nbr  <- df_data %>% filter(Indeks == "NBR", Kategori != "Sehat/Lembap")
    sub_title <- "Fokus Kategori Terganggu & Non-Rapat"
  }

  p_ndvi <- ggplot(df_ndvi, aes(x = Bulan, y = Luas_ribu_ha, fill = Kategori)) +
…
    ) +
    theme(
      plot.title = element_text(face = "bold", size = 11, hjust = 0.5),
      legend.position = "bottom",
      legend.title = element_text(face = "bold", size = 10)
    ) +
    guides(fill = guide_legend(nrow = 2))

  p_nbr <- ggplot(df_nbr, aes(x = Bulan, y = Luas_ribu_ha, fill = Kategori)) +
…
    guides(fill = guide_legend(nrow = 2))

  (p_ndvi + p_nbr) +
    plot_annotation(
      title = "Tren Perubahan Luasan Wilayah Kota Palangka Raya (Jul - Sep)",
      subtitle = sub_title,
      theme = theme(
        plot.title = element_text(face = "bold", size = 13),
        plot.subtitle = element_text(size = 10)
      )
    )
}
```

i) Menjalankan dan menampilkan grafik tren keseluruhan maupun terpilih

```
p_trend_full <- build_trend_plot(df_summary, include_dense = TRUE)
print(p_trend_full)

p_trend_filtered <- build_trend_plot(df_summary, include_dense = FALSE)
print(p_trend_filtered)
```

BAB IV
HASIL DAN PEMBAHASAN

4.1 Hasil

Subbab ini membahas mengengai hasil pengolahan yang mencakup hasil regresi linear, hasil autokorelasi spasial tingkat global maupun lokal, hingga hasil interpretasi indeks spektral citra Sentinel-2. Seluruh hasil ditampilkan secara komparatif antara skala kelurahan dan grid untuk mengidentifikasi pengaruh unit satuan analisis terhadap pola spasial yang dihasilkan.

4.1.1 Hasil Regresi Linear

Analisis regresi linear menggunakan kepadatan titik panas sebagai variabel terikat (Y), sedangkan kepadatan drainase (X_1) dan rata-rata jarak terhadap jalan (X_2) digunakan sebagai variabel bebas. Pengujian dilakukan pada masing-masing satuan kelurahan dan grid untuk memperoleh koefisien hubungan, nilai signifikansi, dan koefisien determinasi.

a. Regresi linear tunggal

Regresi linear tunggal dilakukan pada masing-masing prediktor yakni kepadatan drainase dan rata-rata jarak terhadap jalan. Kepadatan drainase merupakan perbandingan antara panjang kanal drainase (dalam km) dengan luas satuan unit analisis (dalam km persegi). Sedangkan rata-rata jarak terhadap jalan dihitung menggunakan euclidean distance dan diambil nilai rata-rata dari tiap satuan unit analisis. Dari dua variabel tersebut, dilakukan regresi linear dari data dengan satuan analisis tingkat kelurahan dan satuan analisis grid sebesar 1 x 1 kilometer. Hasil dari regresi linear dapat dilihat pada Tabel 4.1.

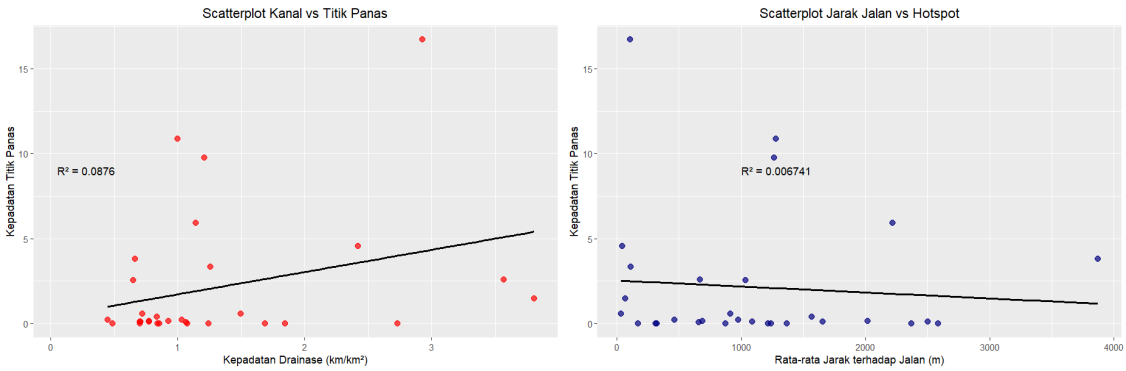
Tabel 4.1 Ringkasan hasil regresi linear tunggal dari masing-masing variabel terhadap kepadatan titik panas

Satuan Analisis	Prediktor (X)	Intersep (β_0)	Koef. (β_1)	R^2	p-value β_1
Kelurahan	Kepadatan drainase	0,41781	1,31115	0,0876	0,11233
Grid	Kepadatan drainase	1,25213	1,38394	0,0297	< 0,00001
Kelurahan	Jarak terhadap jalan	2,54225	-0,00035	0,0067	0,66622
Grid	Jarak terhadap jalan	3,79963	-0,00080	0,0286	< 0,00001

Pada satuan analisis kelurahan, model dengan variabel prediktor berupa kepadatan drainase menghasilkan koefisien sebesar 1,3112 dan R^2 sebesar 0,0876, dengan p-value sebesar 0,11233. Kemudian, model dengan prediktor berupa rata-rata jarak terhadap jalan menunjukkan koefisien sebesar -0,0003517, R^2 sebesar 0,0067, dan p-value sebesar 0,66622. Kedua koefisien prediktor tersebut tidak signifikan pada tingkat 5%. Sedangkan pada satuan analisis grid, model dengan variabel prediktor berupa kepadatan drainase menghasilkan koefisien sebesar 1,3839 dengan R^2 sebesar 0,0297 dan p-value < 0,00001. Adapun model dengan prediktor berupa jarak terhadap jalan menghasilkan koefisien sebesar -0,0008088, R^2 sebesar 0,0286, dan p-value < 0,00001. Kedua prediktor pada satuan analisis grid signifikan pada tingkat 5%.

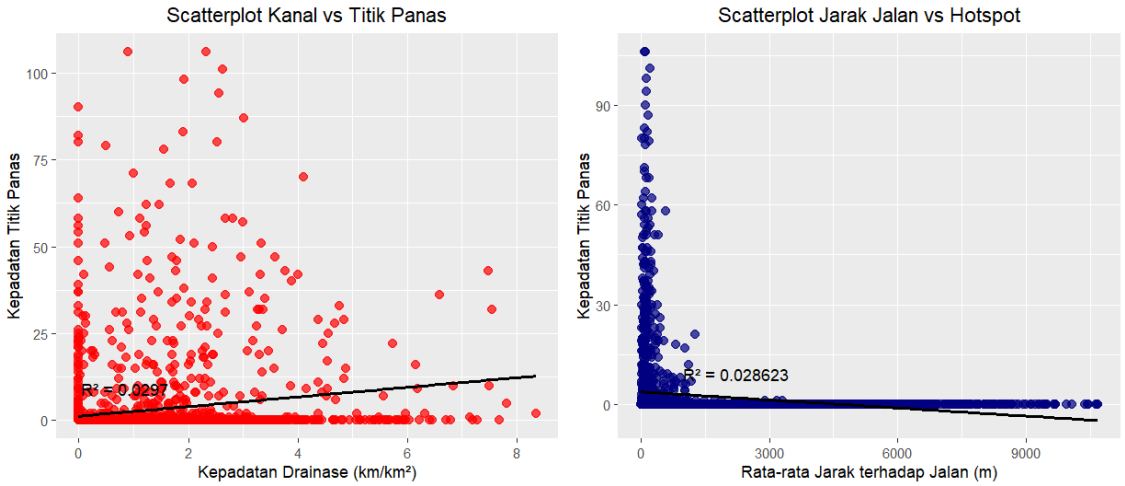
Berdasarkan hasil regresi pada satuan analisis tingkat kelurahan yang dapat dilihat pada Gambar 4.1, hubungan antara kepadatan drainase dan kepadatan titik panas menunjukkan tren

positif dengan nilai $R^2 = 0{,}0876$. Nilai tersebut mengindikasikan bahwa sekitar 8,76% variasi kepadatan titik panas pada tingkat kelurahan dapat dijelaskan oleh keberadaan jaringan kanal. Di sisi lain, variabel rata-rata jarak terhadap jalan hanya menghasilkan nilai $R^2 = 0{,}0067$ yang menunjukkan hubungan negatif sangat lemah. Penggunaan batas administrasi kelurahan ini menghasilkan jumlah sampel yang sedikit dan memicu efek perataan (*smoothing*), sehingga variasi spasial menjadi kurang terlihat secara detail.



Gambar 4.1 Scatterplot regresi linear tunggal dengan satuan analisis kelurahan

Sebaliknya, regresi linear dengan menggunakan satuan analisis grid seperti pada Gambar 4.2 mampu menampilkan variasi spasial yang jauh lebih tinggi meskipun nilai koefisien determinasinya cenderung kecil. Pada unit analisis ini, hubungan kepadatan drainase terhadap titik panas menghasilkan $R^2 = 0{,}0297$, sementara variabel jarak jalan menghasilkan $R^2 = 0{,}0286$. Meskipun nilai R^2 pada variabel jalan tergolong rendah, sebaran titik data pada skala grid memperlihatkan konsentrasi titik panas yang sangat tinggi di area dekat jalan pada rentang 0 hingga 1.000 meter. Ini menunjukkan adanya ambang batas sebelum kepadatan titik panas menjadi 0 pada grid dengan jarak terhadap jalan yang tinggi. Selain itu, analisis berbasis grid ini juga menunjukkan banyaknya unit sel yang tidak memiliki kejadian titik panas sama sekali.



Gambar 4.2 Scatterplot regresi linear tunggal dengan satuan analisis grid 1 x 1 kilometer

Perbedaan hasil dari kedua hasil terrsebut mengonfirmasi adanya fenomena *Modifiable Areal Unit Problem* (MAUP), khususnya *scale effect*. Agregasi data ke dalam unit satuan kelurahan menyebabkan kecilnya variansi lokal yang terdeteksi dan berisiko menghasilkan

hubungan statistik yang kurang representatif. Sementara itu, penggunaan resolusi grid dengan luas wilayah yang lebih kecil menunjukkan adanya pola hubungan non-linier serta batas ambang (*threshold*) pengaruh jarak terhadap jalan terhadap persebaran titik panas.

b. Regresi linear berganda

Berbeda dengan regresi linear tuggal yang menggunakan tiap prediktor seacra terpisah, regresi linear berganda menggunakan kedua prediktor secara bersamaan, dengan bentuk model $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$. Nilai koefisien model dan statistik pengujian tiap model diperoleh melalui estimasi ulang menggunakan data asli pada masing-masing satuan analisis. Ringkasan dari regresi linear berganda dapat dilihat pada Tabel 4.2.

Tabel 4.2 Ringkasan hasil regresi linear berganda terhadap kepadatan titik panas

Satuan	Intersep	β drainase	β jarak	R^2	Adj. R^2	p model
Kelurahan	-0,22513	1,49336	0,0003582	0,0929	0,0257	0,26822
Grid	2,51996	1,06899	-0,0006147	0,0447	0,0440	< 0,00001

Pada satuan kelurahan, persamaan model yang diperoleh memiliki intersep sebesar -0,22513, koefisien kepadatan drainase sebesar 1,49336, dan koefisien jarak terhadap jalan sebesar 0,0003582. Nilai R^2 sebesar 0,0929 dan Adjusted R^2 0,0257 dengan p-value sebesar 0,26822. Nilai p untuk koefisien drainase adalah 0,12097 dan untuk koefisien jarak terhadap jalan adalah 0,69427. Rentang p-value yang berada di atas ambang batas 0,05 menunjukkan bahwa baik variabel drainase maupun jarak jalan tidak memberikan kontribusi yang signifikan secara individual dalam skala unit analisis ini. Hal ini mengindikasikan bahwa variabilitas data yang sudah teragregasi di tingkat kelurahan belum cukup kuat untuk memodelkan persebaran titik panas secara linier.

Pada satuan grid, persamaan model yang diperoleh memiliki intersep sebesar 2,51996, koefisien kepadatan drainase sebesar 1,06899, dan koefisien jarak terhadap jalan sebesar -0,0006147. Nilai R^2 sebesar 0,0447 dan Adjusted R^2 0,0440 dengan p-value sebesar < 0,00001. Nilai p untuk koefisien drainase adalah < 0,00001 dan untuk koefisien jarak terhadap jalan adalah < 0,00001. Penurunan p-value yang signifikan pada skala grid menandakan bahwa peningkatan resolusi spasial dengan cara memperkecil unit satuan analisis mampu menangkap pola hubungan antarvariabel dengan jauh lebih baik. Selain itu, tanda negatif pada koefisien jarak jalan menegaskan bahwa semakin dekat suatu lokasi dengan jalan, maka kepadatan titik panas cenderung meningkat.

Pada satuan analisis tingkat kelurahan model regresi berganda tidak signifikan pada tingkat 5%, sedangkan model pada satuan grid signifikan secara statistik. Sama dengan hasil regresi linear tunggal, perbedaan hasil ini memperlihatkan adanya efek *scaling* akibat *Modifiable Areal Unit Problem* (MAUP) dalam pemodelan spasial. Meskipun nilai R^2 pada skala grid relatif rendah dan menunjukkan lemahnya keterkaitan antar variabel, signifikansi statistiknya menunjukkan bahwa unit grid lebih signifikan secara statistik untuk mendeteksi pengaruh variabel fisik lingkungan secara bersamaan.

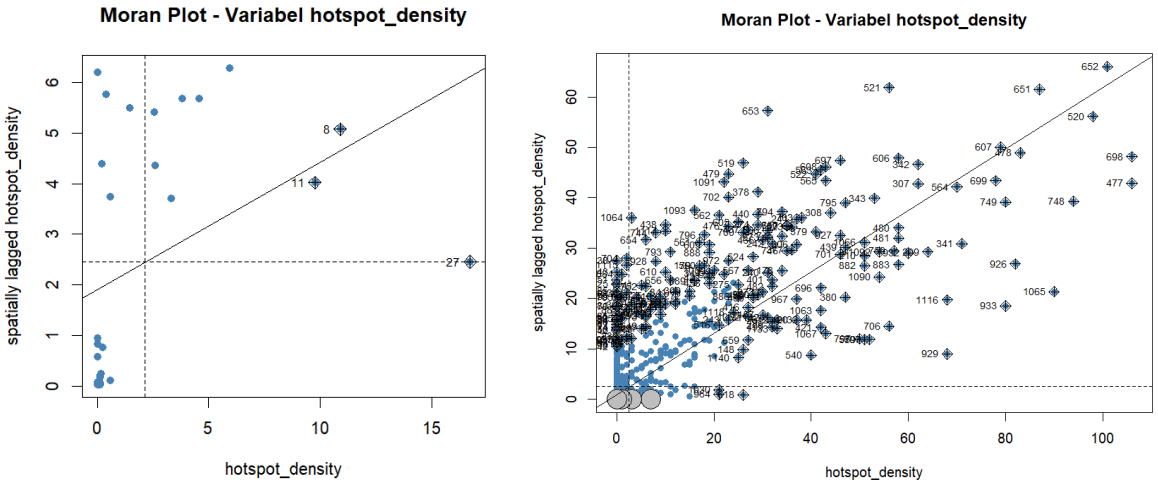
4.1.2 Hasil Autokorelasi Spasial Global (Global Moran's I)

Analisis Global Moran's I dilakukan dengan hubungan ketetanggaan *queen contiguity*. Penggunaan matriks bobot spasial disesuaikan dengan karakteristik geometris masing-masing satuan analisis. Pada satuan kelurahan, digunakan Style S (*variance-stabilizing scheme*) untuk menstabilkan varians data, dan menyimpan *connectivity distribution* antarunit administrasi yang bersifat tidak teratur dan bervariasi secara signifikan. Sederhanyanya pada kelurahan dengan luas area kecil dan berada di dekat pusat kota akan memiliki tetangga lebih banyak daripada kelurahan dengan luas area besar dan terletak di tepi batas administrasi. Sehingga, Style S digunakan untuk menstabilkan variansi tetangga tersebut. Sebaliknya, satuan grid menggunakan Style W (*row-standardized scheme*) karena memiliki struktur ukuran dan bentuk yang seragam, di mana sebagian besar sel memiliki jumlah tetangga yang konstan. Penerapan Style W pada grid menyederhanakan perhitungan spatial lag, sehingga menghasilkan estimasi autokorelasi spasial yang lebih konsisten.

Tabel 4.3 Hasil uji Global Moran's I pada satuan kelurahan dan grid

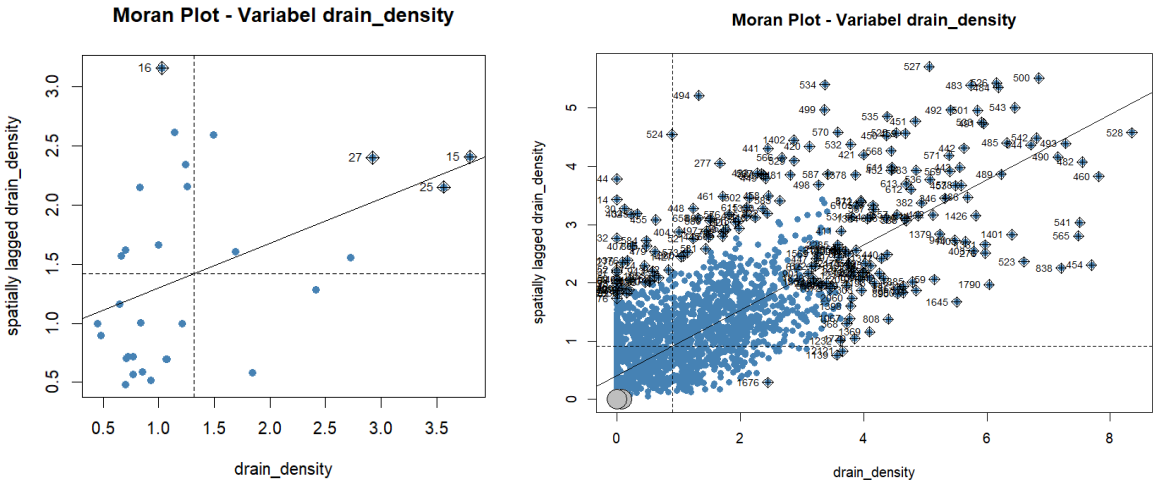
Variabel	Satuan	Moran's I	Expected I	p-value	Signifikansi (5%)
Kepadatan titik panas	Kelurahan	0,2145	-0,0345	0,01180	Ya
Kepadatan titik panas	Grid	0,6083	-0,0004	< 0,0001	Ya
Kepadatan drainase	Kelurahan	0,2350	-0,0345	0,01197	Ya
Kepadatan drainase	Grid	0,5602	-0,0004	< 0,0001	Ya
Rata-rata jarak terhadap jalan	Kelurahan	0,1526	-0,0345	0,06058	Tidak
Rata-rata jarak terhadap jalan	Grid	0,9574	-0,0004	< 0,0001	Ya

Pada variabel kepadatan titik panas, unit satuan kelurahan menghasilkan nilai Moran's I sebesar 0,2145 dengan p-value sebesar 0,01180 yang selaras dengan kemiringan garis regresi yang relatif landai pada Gambar 4.3 (kiri), di mana sebaran data terpusat pada kuadran Low-Low (kiri bawah) dan Low-High (kiri atas) serta memuat beberapa observasi berpengaruh seperti pada ID 8, 11, dan 27 (Kelurahan Bukit Tunggal, Petuk Katimpun, dan Kalampangan). Sebaliknya, satuan grid mencatatkan nilai Moran's I yang jauh lebih tinggi sebesar 0,6083 dengan p-value < 0,0001, terlihat dari kemiringan garis regresi yang sangat curam pada Gambar 4.3 (kanan) dengan konsentrasi data yang rapat di kuadran High-High (kanan atas) seperti ID 652 dan 651 serta tumpukan data pada kuadran Low-Low (kiri bawah). Adanya peningkatan nilai Moran's I menunjukkan adanya peningkatan autokorelasi spasial yang signifikan saat unit analisis berpindah dari skala kelurahan ke grid.



Gambar 4.3 Moran plot kepadatan titik panas pada unit satuan kelurahan (kiri) dan unit satuan grid (kanan)

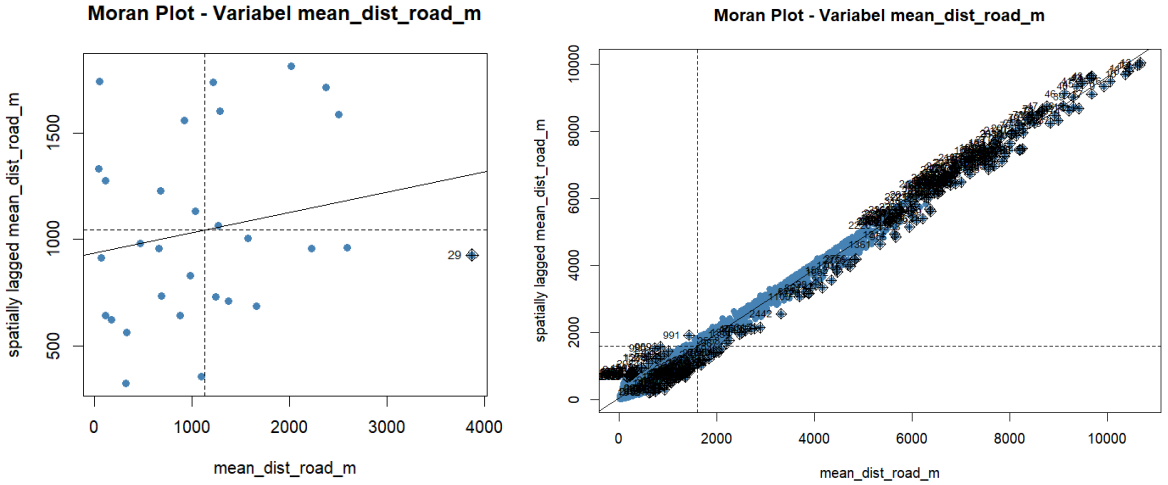
Sementara itu, pada variabel kepadatan drainase, unit satuan kelurahan menghasilkan nilai Moran's I sebesar 0,2350 dengan p-value sebesar 0,01197 yang selaras dengan kemiringan garis regresi pada Gambar 4.4 (kiri). Sebaran datanya terdistribusi pada kuadran Low-Low (kiri bawah) dan High-High (kanan atas) serta memuat beberapa observasi berpengaruh seperti pada ID 15, 16, 25, dan 27 (Kelurahan Panarung, Tanjung Pinang, Bereng Bengkel dan Kalampangan). Sebaliknya, unit satuan grid memiliki nilai Moran's I yang meningkat signifikan menjadi 0,5602 dengan p-value < 0,0001. Hal ini terlihat dari kemiringan garis regresi yang lebih curam pada Gambar 4.4 (kanan) serta konsentrasi data yang sangat rapat sepanjang garis diagonal dari kuadran Low-Low hingga High-High (seperti ID 500, 527, dan 528). Adanya peningkatan nilai Moran's I ini kembali menunjukkan adanya peningkatan autokorelasi spasial yang signifikan akibat perubahan skala analisis dari kelurahan ke grid.



Gambar 4.4 Moran plot kepadatan drainase pada unit satuan kelurahan (kiri) dan unit satuan grid (kanan)

Selanjutnya, pada variabel rata-rata jarak terhadap jalan, unit satuan kelurahan menghasilkan nilai Moran's I sebesar 0,1526 dengan p-value sebesar 0,06058. Nilai tersebut mengindikasikan bahwa autokorelasi spasial pada skala administrasi kelurahan tidak signifikan

pada tingkat signifikansi 5%. Sebaliknya, analisis pada satuan grid memiliki nilai Moran's I yang sangat tinggi yaitu sebesar 0,9574 dan signifikan secara statistik dengan p-value < 0,0001. Peningkatan nilai yang cukup jauh ini menunjukkan bahwa keberadaan pola *clustering* pada variabel jarak terhadap jalan jauh lebih kuat pada skala lokal. Secara keseluruhan, ketiga variabel menunjukkan nilai Moran's I lebih tinggi pada unit satuan grid dibandingkan unit satuan kelurahan, meskipun interpretasi tetap perlu memperhatikan perbedaan jumlah unit analisis, variasi geometri, serta jenis standardisasi bobot spasial yang digunakan.



Gambar 4.5 Moran plot rata-rata jarak terhadap jalan pada unit satuan kelurahan (kiri) dan unit satuan grid (kanan)

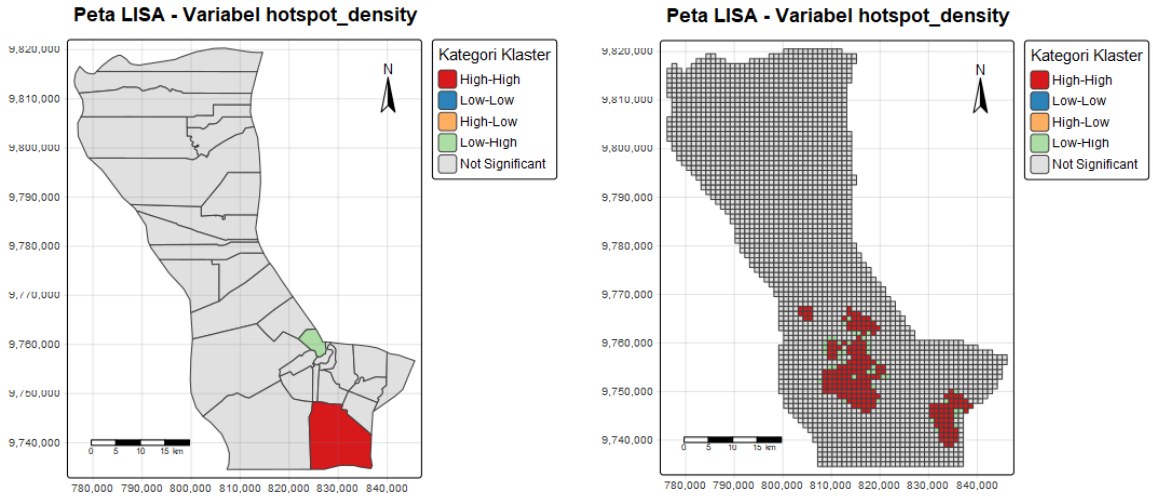
4.1.3 Hasil Autokorelasi Spasial Lokal (LISA)

Perhitungan autokorelasi spasial *Local Indicators of Spatial Association* (LISA) dilakukan untuk mengidentifikasi keberadaan pola *spatial cluster* serta identifikasi *spatial outliers* pada tingkat signifikansi $\alpha = 0{,}05$. Hasil perhitungannya dikategorikan ke dalam empat kelompok *cluster*, yaitu High-High (HH), High-Low (HL), Low-High (LH), dan Low-Low (LL), serta *cluster* lokasi yang tidak signifikan secara statistik. Ringkasan dari hasil pemrosesan LISA dapat dilihat pada Tabel 4.4. Dengan kolom HH, HL, LH dan LL menunjukkan jumlah *cluster* berdasarkan unit satuan.

Tabel 4.4 Jumlah dan tingkat signifikansi tiap *cluster* pada tiap variabel dan unit satuan analisis

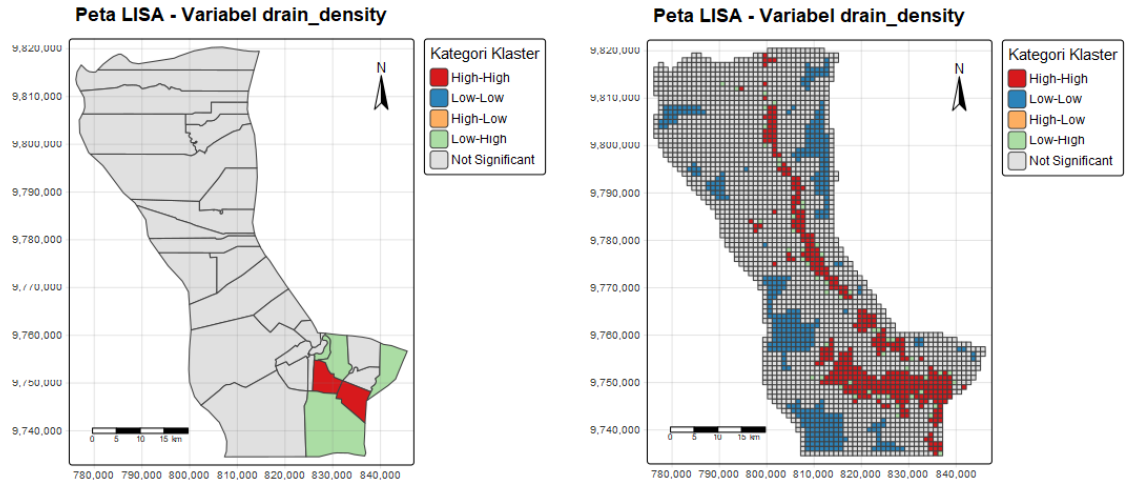
Variabel	Satuan	HH	HL	LH	LL	Tidak signifikan	% signif.
Kepadatan titik panas	Kelurahan	1	0	1	0	28	6,67%
Kepadatan titik panas	Grid	199	0	41	0	2519	8,70%
Kepadatan drainase	Kelurahan	2	0	4	0	24	20,00%
Kepadatan drainase	Grid	353	0	52	368	1986	28,02%
Rata-rata jarak terhadap jalan	Kelurahan	0	0	0	0	30	0,00%
Rata-rata jarak terhadap jalan	Grid	534	0	0	456	1769	35,88%

Pada satuan kelurahan (Gambar 4.6 kiri), hasil LISA untuk variabel kepadatan titik panas hanya mengidentifikasi satu wilayah High-High (nilai kepadatan tinggi yang dikelilingi oleh kepadatan tinggi pula) di Kelurahan Sabaru di bagian selatan dan satu wilayah Low-High (nilai kepadatan rendah yang dikelilingi nilai kepadatan tinggi) di Kelurahan Tumbang Rungan. Karena hanya terdapat dua wilayah terklasifikasi dari total 30 area, maka dinyatakan hanya 6,67% area signifikan secara statistik. Sedangkan pada satuan grid (Gambar 4.6 kanan), hasil LISA menunjukkan 199 grid dengan klasifikasi High-High yang terkonsentrasi di wilayah tengah ke selatan serta tenggara serta 41 wilayah yang terklasifikasi Low-High. Pada unit analisis tingkat grid, terdapat kenaikan jumlah *cluster* HH dan LH, serta jumlag *cluster* yang tidak signifikan. Jumlah dari grid yang signifikan yakni 8,7% dari keseluruhan wilayah. Adanya perbedaan dari jumlah *cluster* HH dan LH antara unti satuan kelurahan dan grid kembali menunjukkan adanya efek dari agregasi data pada skala administrasi yang bersifat meratakan batas klaster ke dalam satu wilayah besar, sementara unit satuan grid mampu mendeteksi lokasi-lokasi *cluster* titik panas lokal lebih baik.



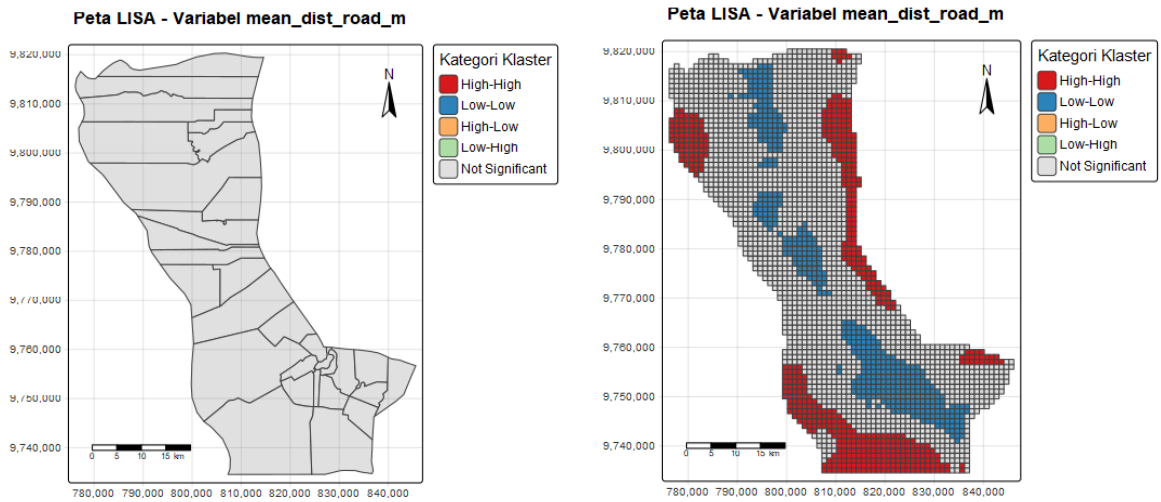
Gambar 4.6 Peta klasifikasi LISA kepadatan titik panas pada satuan kelurahan (kiri) dan satuan grid (kanan)

Pada satuan kelurahan (Gambar 4.7 kiri), hasil LISA untuk variabel kepadatan drainase mengidentifikasi dua wilayah High-High (nilai kepadatan tinggi yang dikelilingi oleh nilai tinggi) di Kelurahan Panarung dan Kalampangan, serta empat wilayah Low-High (nilai kepadatan rendah yang dikelilingi nilai tinggi), di Kelurahan Pahandut, Tanjung Pinang, Kameloh Baru dan Sabaru, yang terkonsentrasi di bagian selatan wilayah studi, dengan persentase area signifikan sebesar 20,00% dari total unit studi. Sementara itu, pada satuan grid (Gambar 4.7 kanan), hasil LISA menunjukkan 353 grid High-High, 52 grid Low-High, serta memicu kemunculan 368 grid Low-Low yang membentuk pola kelompok memanjang dengan total unit signifikan mencapai 28,02% dari total unit studi. Kenaikan jumlah klaster serta munculnya *cluster* Low-Low pada skala grid ini semakin menunjukkan bahwa efek agregasi dapat menyamarkan variasi lokal.



Gambar 4.7 Peta klasifikasi LISA kepadatan drainase pada satuan kelurahan (kiri) dan satuan grid (kanan)

Pada satuan kelurahan (Gambar 4.8 kiri), hasil LISA untuk variabel rata-rata jarak terhadap jalan sama sekali tidak mengidentifikasi wilayah High-High, Low-High, High-Low, maupun Low-Low, sehingga seluruh 30 area terklasifikasi ke dalam kategori tidak signifikan. Sedangkan pada satuan grid (Gambar 4.8 kanan), hasil LISA menunjukkan perbedaan yang yang kentara dengan 534 grid berklasifikasi High-High dan 456 grid berklasifikasi Low-Low, dengan total unit signifikan mencapai 35,88% dari total unit analisis. Perbedaan ini kembali menguatkan argumen bahwa efek agregasi data pada unit administrasi kelurahan dapat menghamburkan variasi spasial yang terjadi.



Gambar 4.8 Peta klasifikasi LISA rata-rata jarak terhadap jalan pada satuan kelurahan (kiri) dan satuan grid (kanan)

Secara keseluruhan, hasil LISA menunjukkan bahwa penggunaan satuan analisis grid nampak lebih unggul dalam mengungkap struktur autokorelasi spasial lokal dibandingkan satuan kelurahan. Efek agregasi pada unit administrasi kelurahan menyebabkan hilangnya variasi spasial antarwilayah dan dapat menghilangkan klaster spasial pada variabel tertentu seperti jarak terhadap jalan. Sebaliknya, satuan grid mampu memetakan lokasi-lokasi *hotspot* (High-High) maupun *coldspot* (Low-Low) dengan baik.

4.1.4 Hasil Getis-Ord-Gi*

Getis-Ord Gi* digunakan untuk mengidentifikasi konsentrasi nilai tinggi (*hotspot*) dan konsentrasi nilai rendah (*coldspot*), menggunakan ambang *Z-score* ±1,65, ±1,96, dan ±2,58 untuk tingkat kepercayaan 90%, 95%, dan 99%. Perhitungan menggunakan matriks ketetanggaan queen contiguity serta bobot biner (Style B). Ringkasan jumlah *cluster* dapat dilihat pada Tabel 4.5.

Tabel 4.5 Jumlah *cluster* berdasarkan hasil Getis-Ord-Gi*

Variabel	Satuan	Hot 99%	Hot 95%	Hot 90%	Cold 90%	Cold 95%	Cold 99%	Tidak sig.
Kepadatan titik panas	Kelurahan	0	3	3	0	0	0	24
Kepadatan titik panas	Grid	217	27	17	0	0	0	2498
Kepadatan drainase	Kelurahan	3	3	2	1	0	0	21
Kepadatan drainase	Grid	299	129	92	255	466	0	1518
Rata-rata jarak terhadap jalan	Kelurahan	0	1	2	2	1	0	24
Rata-rata jarak terhadap jalan	Grid	480	82	50	449	745	0	953

Pada satuan kelurahan, variabel kepadatan titik panas memiliki enam hotspot signifikan, terdiri atas tiga kelurahan pada tingkat kepercayaan 95% dan tiga pada 90%, tanpa coldspot signifikan. Variabel kepadatan drainase menunjukkan delapan hotspot (tiga pada 99%, tiga pada 95%, dan dua pada 90%) serta satu coldspot pada 90%. Variabel rata-rata jarak terhadap jalan memperlihatkan tiga hotspot dan tiga coldspot, dengan 24 kelurahan tidak signifikan.

Pada satuan grid, kepadatan titik panas menunjukkan 261 hotspot signifikan (217 pada 99%, 27 pada 95%, dan 17 pada 90%) tanpa coldspot signifikan. Kepadatan drainase menunjukkan 520 hotspot dan 721 coldspot, sedangkan rata-rata jarak terhadap jalan menunjukkan 612 hotspot dan 1.194 coldspot. Jumlah unit tanpa klasifikasi signifikan masing-masing adalah 2.498, 1.518, dan 953 grid.

Berikut ini merupakan hasil pemeringkatan Getis-Ord Gi* yang memungkinkan identifikasi nama kelurahan dan ID grid dengan Z-score tertinggi. Nilai pada tabel berikut ditampilkan dari hasil pemeringkatan masing-masing variabel. Tabel 4.6 menunjukkan pemeringkatan berdasarkan kelurahan dan Tabel 4.7 menunjukkan pemeringkatan berdasarkan grid.

Tabel 4.6 Kelurahan dengan Getis-Ord Gi* signifikan menurut variabel

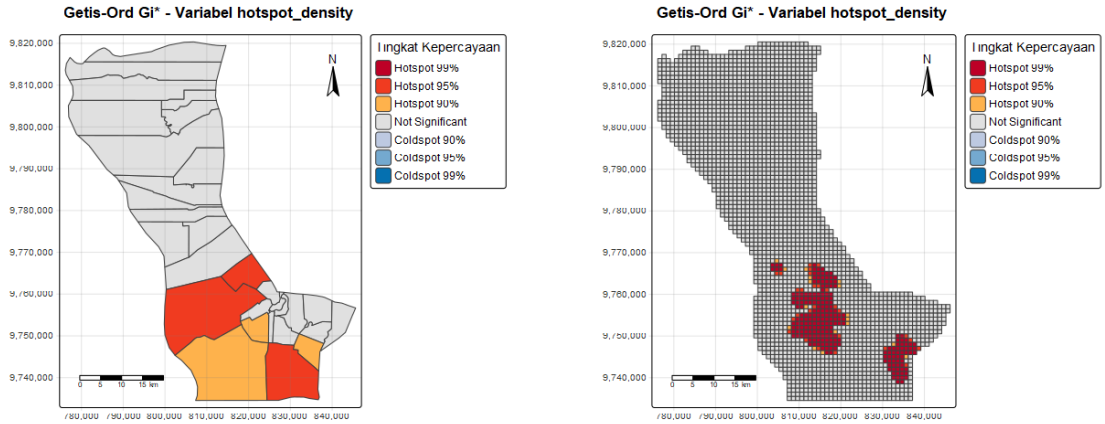
Variabel	Kelurahan	Nilai asli	Z-score	Kategori
Kepadatan titik panas	Sabaru	5,920	2,331	Hotspot 95%
Kepadatan titik panas	Bukit Tunggal	10,888	2,172	Hotspot 95%
Kepadatan titik panas	Petuk Katimpun	9,748	1,986	Hotspot 95%
Kepadatan drainase	Tanjung Pinang	1,032	3,275	Hotspot 99%

Variabel	Kelurahan	Nilai asli	Z-score	Kategori
Kepadatan drainase	Panarung	3,804	2,891	Hotspot 99%
Kepadatan drainase	Kalampangan	2,924	2,757	Hotspot 99%
Rata-rata jarak terhadap jalan	Gaung Baru	2.370,537	2,103	Hotspot 95%
Rata-rata jarak terhadap jalan	Panjehang	2.504,232	1,928	Hotspot 90%
Rata-rata jarak terhadap jalan	Pager	2.017,251	1,808	Hotspot 90%

Tabel 4.7 Kelurahan dengan Getis-Ord Gi* signifikan menurut variabel

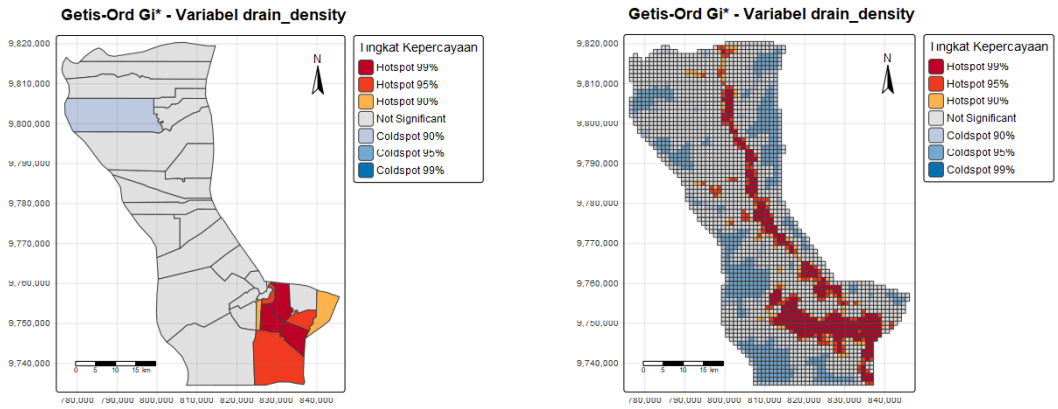
Variabel	ID grid	Nilai asli	Z-score	Kategori
Kepadatan titik panas	GRID_652	101,000	20,136	Hotspot 99%
Kepadatan titik panas	GRID_651	87,000	18,476	Hotspot 99%
Kepadatan titik panas	GRID_521	56,000	17,546	Hotspot 99%
Kepadatan drainase	GRID_500	6,842	11,412	Hotspot 99%
Kepadatan drainase	GRID_527	5,063	11,355	Hotspot 99%
Kepadatan drainase	GRID_526	6,158	11,047	Hotspot 99%
Rata-rata jarak terhadap jalan	GRID_43	9.677,814	11,525	Hotspot 99%
Rata-rata jarak terhadap jalan	GRID_44	9.676,328	11,453	Hotspot 99%
Rata-rata jarak terhadap jalan	GRID_42	9.641,243	11,426	Hotspot 99%

Untuk kepadatan titik panas pada satuan kelurahan, nilai Z-score tertinggi ditemukan di Sabaru (2,331), Bukit Tunggal (2,172), dan Petuk Katimpun (1,986), ketiganya termasuk kategori hotspot 95%. Pada satuan grid, Z-score tertinggi ditemukan pada GRID_652 (20,136), GRID_651 (18,476), dan GRID_521 (17,546) yang mana ketiganya masuk dalam kategori hotspot 99%. Secara visual, peta grid memperlihatkan konsentrasi hotspot terutama di tengah hingga selatan serta pada bagian tenggara. Sedangkan pada peta kelurahan menunjukkan sebaran yang serupa walau terjadi generalisasi karena luas wilayah kelurahan yang lebar (Gambar 4.9).



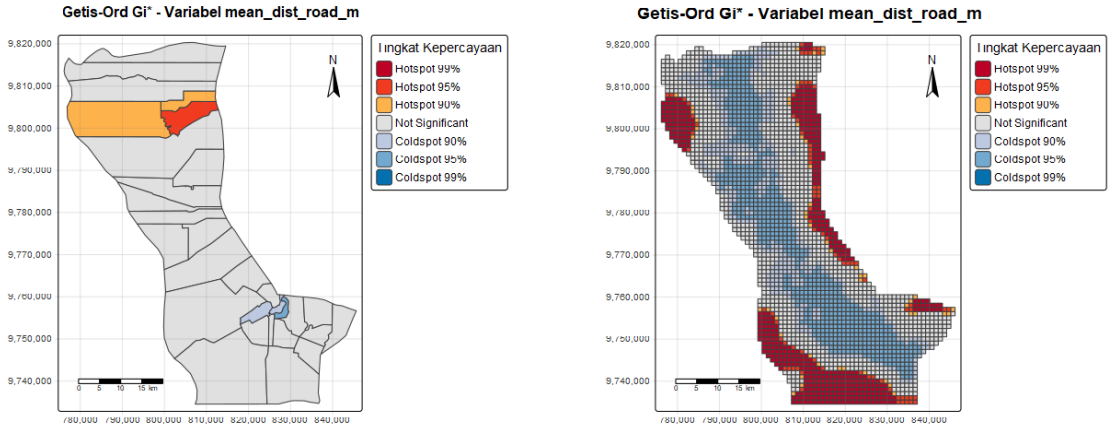
Gambar 4.9 Peta klasifikasi Getis-Ord Gi* kepadatan titik panas pada satuan kelurahan (kiri) dan satuan grid (kanan)

Untuk kepadatan drainase, Z-score hotspot kelurahan tertinggi ditemukan di Tanjung Pinang (3,275), Panarung (2,891), dan Kalampangan (2,757), yang mana ketiganya masuk dalam kategori hotspot 99%, dan satu coldspot 90% ditemukan di Pager (−1,680). Pada grid, konsentrasi nilai tinggi tertinggi diperoleh di GRID_500 (11,412), GRID_527 (11,355), dan GRID_526 (11,047). Kelompok hotspot drainase pada peta grid terlihat memanjang dari bagian utara ke tengah dan menyebar lebih luas pada bagian selatan serta tenggara. Sementara pada peta kelurahan, *hotspot* terlihat berkumpul di sisi tenggara Kota Palangka Raya. Selain itu, peta grid juga menunjukkan variasi spasial yang lebih baik bila dibandingkan dengan peta kelurahan.



Gambar 4.10 Peta klasifikasi Getis-Ord Gi* kepadatan drainase pada satuan kelurahan (kiri) dan satuan grid (kanan)

Untuk rata-rata jarak terhadap jalan, *hotspot* unit analisis kelurahan ditemukan di Gaung Baru, Panjehang, dan Pager, sedangkan *coldspot* ditemukan di Palangka, Pahandut Seberang, dan Pahandut. Pada satuan grid, Z-score hotspot tertinggi terdapat pada GRID_43 (11,525), GRID_44 (11,453), dan GRID_42 (11,426). Peta grid memperlihatkan beberapa kelompok hotspot pada bagian utara, tengah, dan selatan, serta coldspot yang menyebar di sejumlah bagian wilayah lainnya. Sedangkan pada peta kelurahan terlihat bahwa *coldspot* berada pada wilayah pusat kota dan *hotspot* berada di sisi utara kota.



Gambar 4.11 Peta klasifikasi Getis-Ord Gi* rata-rata jarak terhadap jalan pada satuan kelurahan (kiri) dan satuan grid (kanan)

4.1.5 Hasil Pengolahan Indeks Spektral Sentinel-2

a) Normalized Difference Vegetation Index (NDVI)

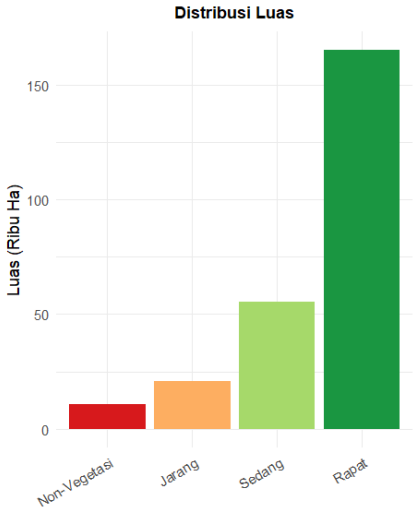
Indeks NDVI diklasifikasikan menjadi empat kategori, yakni non-vegetasi untuk nilai di bawah 0,30; vegetasi jarang untuk 0,30 hingga kurang dari 0,60; vegetasi sedang untuk 0,60 hingga kurang dari 0,78; dan vegetasi rapat untuk nilai 0,78 atau lebih. Ambang batas klasifikasi tersebut didasarkan pada histogram gabungan dari ketiga bulan, kemudian dipilih titik-titik *inflection point*. Skrip untuk perhitungan ini tidak dilampirkan pada laporan ini namun dapat diakses melalui GitHub https://github.com/AntaraAntariksa/PDS-midterm-2026.git

Tabel 4.8 Luas kategori klasifikasi NDVI per bulan

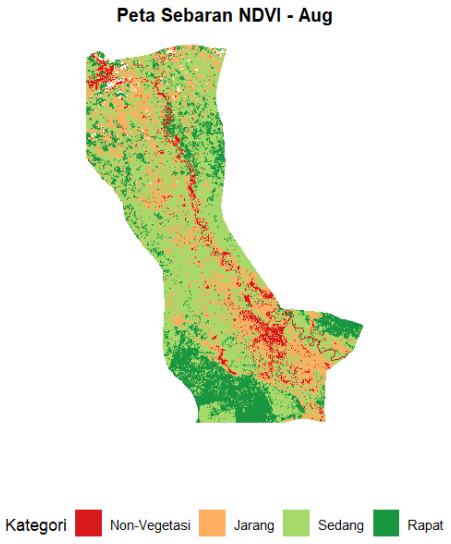
Kategori NDVI	Juli 2026 (ribu Ha)	Agustus 2026 (ribu Ha)	September 2026 (ribu Ha)
Non-vegetasi	10,914	15,132	82,322
Vegetasi jarang	20,810	60,889	91,702
Vegetasi sedang	55,414	126,997	5,252
Vegetasi rapat	164,960	47,730	0,004

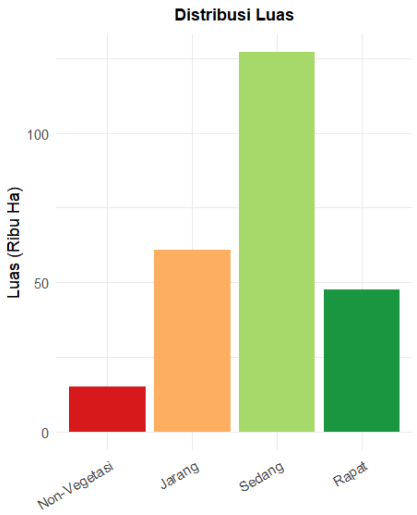
Pada Juli 2026, sebaran vegetasi rapat terlihat dominan di sebagian besar wilayah teramati (Gambar), dengan kelas vegetasi sedang, vegetasi jarang, dan non-vegetasi tersebar pada beberapa bagian wilayah. Pada Agustus 2026, terjadi penurunan pada jumlah vegetasi rapat mencapai 50% dari luas area sebelumnya dan kategori vegetasi sedang tampak menempati bagian terbesar dalam grafik distribusi luas. Kemudia pada September 2026, kategori vegetasi jarang dan non-vegetasi mendominasi area yang masih memiliki nilai piksel, sementara kategori vegetasi rapat hampir tidak terlihat. Perlu diketahui bahwa pada proses pengolahan ini melibatkan *cloud masking* dimana piksel yang teridentifikasi berupa awan tidak digunakna pada pemrosesan. Alasan tersebut dapat menjadi alasan terkait adanya wilayah transparan pada hasil, dimana pada area tersebut terdapat piksel tidak valid yang kemudian dilakukan *masking*.


Peta Sebaran NDVI - Jul
Kategori
Non-Vegetasi
Jarang
Sedang
Rapat

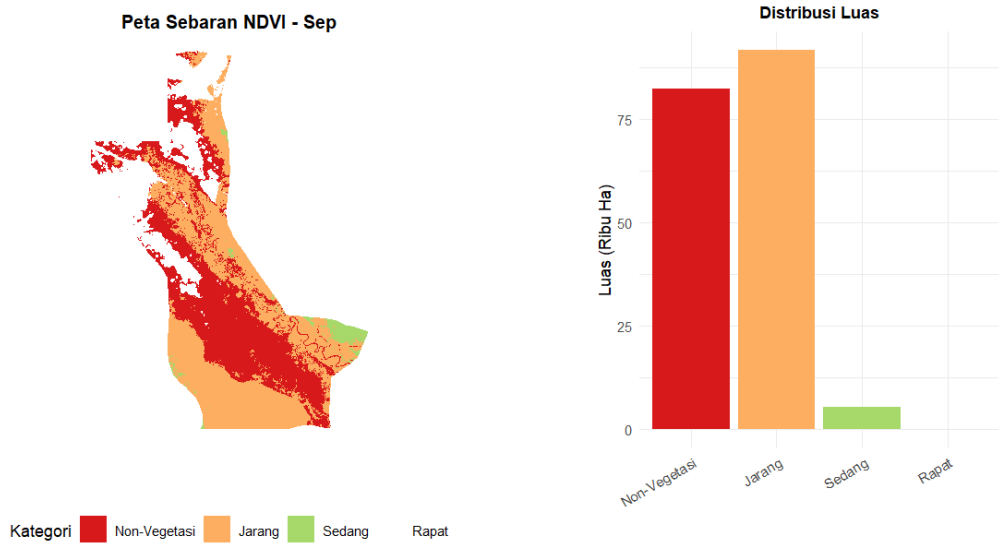

Distribusi Luas
Luas (Ribu Ha)
150
100
50
0
Non-Vegetasi
Jarang
Sedang
Rapat

(a)


Peta Sebaran NDVI - Aug
Kategori
Non-Vegetasi
Jarang
Sedang
Rapat


Distribusi Luas
Luas (Ribu Ha)
100
50
0
Non-Vegetasi
Jarang
Sedang
Rapat

(b)



(c)

Gambar 4.12 Peta persebaran kelas NDVI dan grafik distribusi luas bulan (a) Juli 2026, (b) Agustus 2026, dan (c) September 2026

Secara keseluruhan, pemantauan berbasis indeks NDVI memperlihatkan adanya tren penurunan tutupan vegetasi yang signifikan di wilayah studi sepanjang periode Juli hingga September 2026. Perubahan tersebut ditandai dengan dominasi vegetasi rapat pada bulan Juli yang secara bertahap menyusut dan bergeser menjadi vegetasi sedang pada bulan Agustus, hingga didominasi oleh kategori vegetasi jarang serta non-vegetasi pada bulan September. Meskipun demikian, interprestasi terhadap perubahan luas tutupan lahan tetap harus memperhatikan luasan piksel valid akibat *cloud masking*, di mana total area teramati masing-masing mencapai 252.098 ribu ha pada bulan Juli, 250.748 ribu ha pada bulan Agustus, dan 179.280 ribu ha pada bulan September. Oleh karena itu, penurunan kelas vegetasi rapat yang terdeteksi tidak hanya mencerminkan degradasi tutupan lahan di lapangan, tetapi juga dipengaruhi oleh keterbatasan area piksel bebas awan pada citra satelit yang diolah.

b) Normalized Burnt Ratio (NBR)

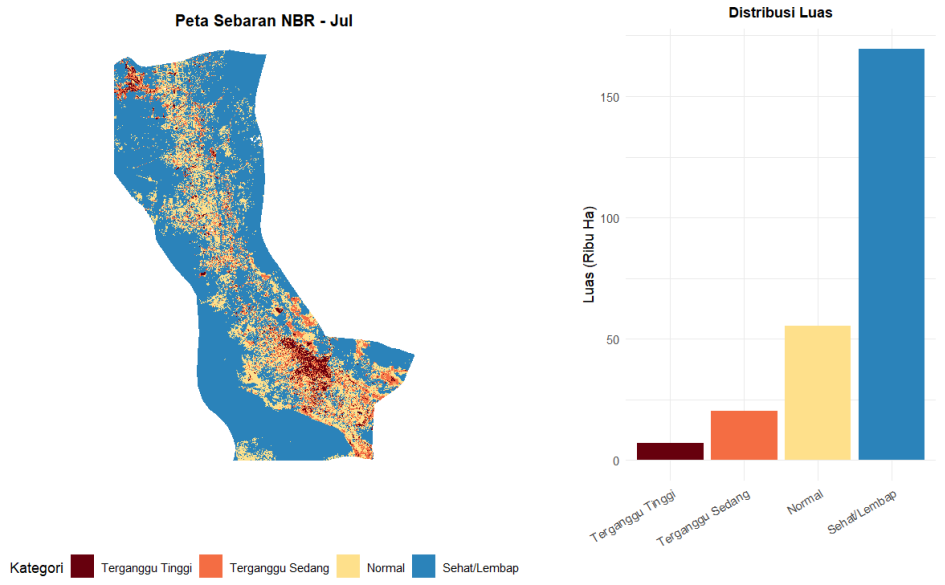
Indeks Normalized Burn Ratio (NBR) diklasifikasikan menjadi empat kategori, yakni terganggu tinggi untuk nilai di bawah 0,05; terganggu sedang untuk 0,05 hingga kurang dari 0,35; normal untuk 0,35 hingga kurang dari 0,60; dan sehat/lembap untuk nilai 0,60 atau lebih. Ambang batas klasifikasi tersebut didasarkan pada histogram gabungan dari ketiga bulan, kemudian dipilih titik-titik *inflection points*. Skrip untuk perhitungan ini tidak dilampirkan pada laporan ini namun dapat diakses melalui GitHub https://github.com/AntaraAntariksa/PDS-midterm-2026.git.

Tabel 4.9 Luas kategori klasifikasi NBR per bulan

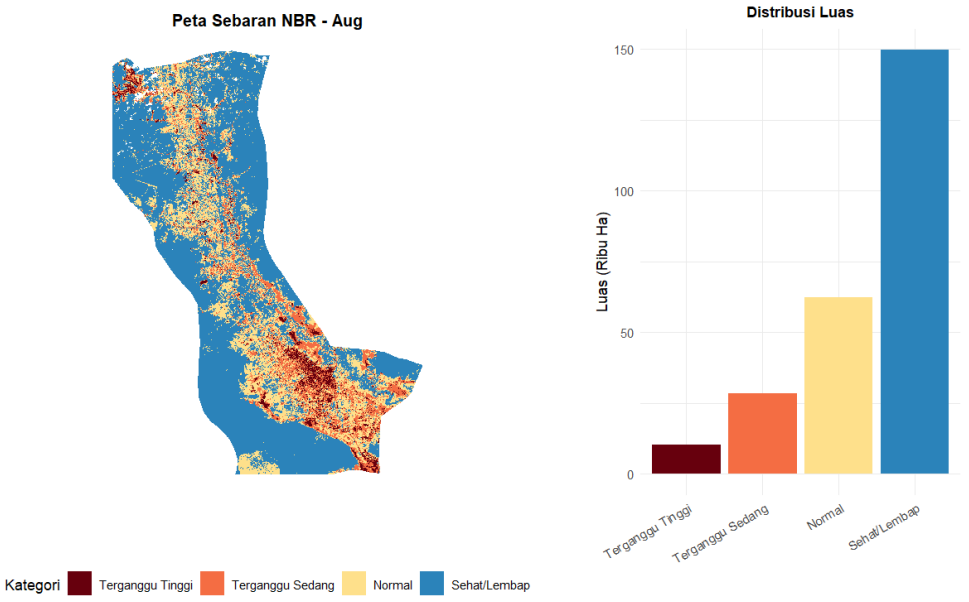
Kategori NBR	Juli 2026 (ribu Ha)	Agustus 2026 (ribu Ha)	September 2026 (ribu Ha)
Terganggu tinggi	7,178	10,159	8,463
Terganggu sedang	20,225	28,556	37,887

Kategori NBR	Juli 2026 (ribu Ha)	Agustus 2026 (ribu Ha)	September 2026 (ribu Ha)
Normal	55,329	62,332	49,556
Sehat/lembap	169,364	149,701	83,375

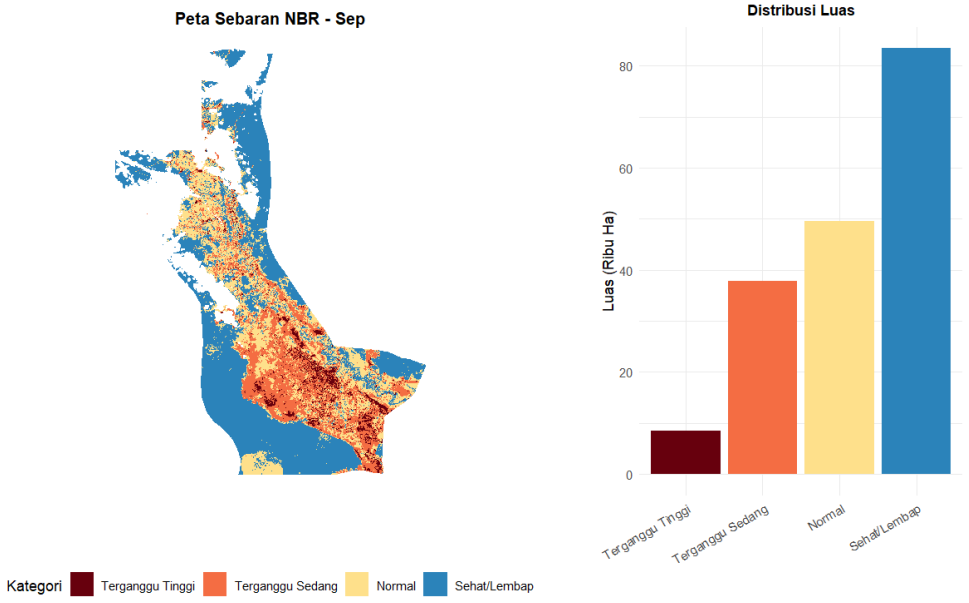
Pada Juli 2026, kondisi tutupan lahan didominasi oleh kategori sehat/lembap di sebagian besar wilayah teramati, dengan kelompok kategori terganggu tinggi dan terganggu sedang terutama tersebar di bagian tengah hingga tenggara. Pada Agustus 2026, terjadi peningkatan pada kelas terganggu tinggi dan terganggu sedang seiring dengan penurunan luasan area sehat/lembap. Selanjutnya pada September 2026, meskipun kategori sehat/lembap masih mencatatkan luasan terbesar, kategori terganggu sedang mengalami kenaikan signifikan yang mendominasi kawasan selatan pada piksel valid. Klasifikasi NBR bulanan dalam penelitian ini merupakan hasil pengelompokan nilai spektral dan tidak secara langsung mengukur tingkat keparahan kebakaran secara absolut, di mana penilaian dampak kebakaran sebelum–sesudah kejadian memerlukan indeks perubahan seperti dNBR dan informasi pendukung.



(a)



(b)



(c)

Gambar 4.13 Peta persebaran kelas NBR dan grafik distribusi luas bulan (a) Juli 2026, (b) Agustus 2026, dan (c) September 2026

Secara keseluruhan, hasil indeks spektral NBR mengindikasikan adanya penurunan kelembapan dan peningkatan tingkat gangguan vegetasi di wilayah studi sepanjang periode Juli hingga September 2026. Perubahan tersebut ditandai dengan dominasi kategori sehat/lembap pada bulan Juli yang secara bertahap mengalami penyusutan, diiringi perluasan kategori terganggu sedang dan terganggu tinggi hingga bulan September. Meskipun demikian, interpretasi perubahan luas kategori NBR harus memperhitungkan keterbatasan piksel valid

akibat *cloud masking*, di mana total area teramati masing-masing mencapai 252.096 ribu ha pada bulan Juli, 250.748 ribu ha pada bulan Agustus, dan 179.281 ribu ha pada bulan September. Oleh karena itu, tingkat gangguan yang terdeteksi tidak hanya merepresentasikan dinamika kebasahan lahan di lapangan, tetapi juga dipengaruhi oleh variasi cakupan area piksel bebas awan pada citra satelit yang diolah.

4.2 Pembahasan

Subbab ini merupakan pembahasan mengenai integrasi dari hasil regresi linear, Global Moran's I, Local Indicators of Spatial Association (LISA), Getis–Ord Gi*, dan indeks spektral Sentinel-2 untuk menilai pola titik panas di Kota Palangka Raya selama Agustus 2026. Hasil temuan kemudian dibandingkan terhadap kondisi wilayah Kota Palangka Raya menggunakan laporan instansi dan pemberitaan lapangan. Perlu dicatat bahwa titik panas hasil deteksi satelit tidak selalu merupakan titik api dan tidak akan sama dengan kejadian karhutla yang diverifikasi petugas, serta luas lahan terbakar tidak dapat diukur menggunakan hasil dari citra satelit secara independen.

4.2.1 Persebaran Spasial Titik Panas dan Kesesuaiannya dengan Kondisi Karhutla 2026

Pada satuan kelurahan, hasil Getis–Ord Gi* mengidentifikasi enam wilayah dengan konsentrasi nilai kepadatan titik panas tinggi, yakni Sabaru, Bukit Tunggal, Petuk Katimpun, Menteng, Kereng Bangkirai, dan Kalampangan. Sabaru, Bukit Tunggal, dan Petuk Katimpun termasuk kelas hotspot statistik pada tingkat kepercayaan 95% sedangkan tiga wilayah lainnya berada pada tingkat 90%. Kemudian, hasil LISA lebih selektif dimana hanya Sabaru termasuk klaster High–High, sedangkan Tumbang Rungan tergolong Low–High. Perbedaan ini bukan merupakan kontradiksi karena LISA menguji hubungan nilai lokal dengan nilai tetangganya, sementara Gi* menguji konsentrasi nilai dalam lingkungan spasial.

Pada satuan grid 1 × 1 km, terdapat 261 grid hotspot kepadatan titik panas menurut Getis–Ord Gi*, meliputi 217 grid pada kepercayaan 99%, 27 pada 95%, dan 17 pada 90%. Pola spasialnya terkonsentrasi di bagian tengah hingga selatan, termasuk bagian tenggara Kota Palangka Raya. Dari tabel ranking grid yang diperoleh setelah proses ekspor, diketahui 2.367 dari 2.759 unit (85,79%) memiliki kepadatan titik panas nol, sedangkan 392 unit memiliki satu atau lebih deteksi. Distribusi yang tidak merata ini memperlihatkan bahwa persebaran titik panas pada bulan Agustus terkonsentrasi pada sebagian kecil unit grid.

Kecenderungan titik panas untuk berkumpul secara spasia, dibuktingan dengan hasil autokorelasi spasial, cukup selaras dengan laporan kejadian di lapangan pada bulan yang dianalisis. Pemeriksaan berbagai media massa menemukan lokasi bekas titik panas pada area Bukit Tunggal, Petuk Katimpun, Kalampangan, Sabaru, dan Kereng Bangkirai selama periode 14-31 Agustus 2026. (RRI, 2026a-g). Selain itu, data BPBD yang diberitakan oleh ANTARA menunjukkan bahwa di Kota Palangka Rata terjadi 298 kejadian kebakaran dengan luas 261,41 ha dalam periode 1 Juni hingga 19 Agustus 2026. Dari 19 Agustus hingga 16 September 2026, angka ini melonjak hingga 567 kejadian dan 1.201,15 ha area terbakar (ANTARA, 2026a-c). Data-data tersebut mendukung adanya *hotspot* statistik pada Sabaru dan Kalampangan di

Sebangau. Dengan demikian, hasil penelitian dinilai cukup sesuai pada tingkat kecenderungan wilayah, tetapi ketepatan lokasi dan kelengkapan deteksi belum dapat dinyatakan tervalidasi secara spasial.

4.2.2 Hubungan Kepadatan Drainase dan Jarak terhadap Jalan dengan Titik Panas

Hasil regresi menunjukkan bahwa arah hubungan kedua prediktor cenderung konsisten pada analisis regresi linear tunggal dimana kepadatan drainase berkoefisien positif, sedangkan jarak terhadap jalan berkoefisien negatif. Di tingkat kelurahan, regresi sederhana drainase menghasilkan R^2 sebesar 0,0876 dengan p-value sebesar 0,11233, dan jarak terhadap jalan menghasilkan R^2 sebesar 0,0067 dengan p-value sebesar 0,66622. Kedua hubungan tidak signifikan pada tingkat signifikansi 5%. Kemudian, regresi linier berganda pada unit analisis kelurahan menghasilkan R^2 sebesar 0,0929 dan p-value sebesar 0,26822. Pada model ini, koefisien jarak berubah positif menjadi 0,0003582. Perubahan tanda ini menunjukkan bahwa arah hubungan pada unit analisis kelurahan tidak stabil ketika kedua prediktor dianalisis bersama, sehingga interpretasi perlu dilakukan secara hati-hati.

Di tingkat grid, koefisien regresi linear tunggal drainase sebesar 1,38394 dengan R^2 sebesar 0,0297. Untuk model jarak terhadap jalan memiliki koefisien sebesar −0,00080 per meter dengan R^2 sebesar 0,0286 dengan p < 0,00001 untuk masing-masing prediktor. Pada regresi berganda, koefisien drainase menjadi 1,06899 dan koefisien jarak menjadi −0,0006147 per meter, dengan R^2 sebesar 0,0447 serta p model < 0,00001. Secara statistik, hasil ini mengindikasikan adanya asosiasi positif kepadatan drainase dan asosiasi negatif jarak jalan dengan kepadatan titik panas di tingkat grid. Namun, model tersebut hanya menjelaskan 4,47% dari variasi yang ada, sehingga kedua variabel tidak dapat dikategorikan sebagai faktor pendorong utama dari kepadatan titik panas.

Koefisien jarak yang negatif dapat sesuai dengan hipotesis bahwa lokasi yang lebih dekat jaringan jalan relatif lebih mudah diakses dan lebih mungkin mengalami gangguan manusia. Akan tetapi, jarak jalan tidak mengukur terkait jumlah penduduk, aktivitas pembukaan lahan, penggunaan lahan, intensitas patroli, ataupun sumber penyalaan. Bahkan dalam kasus tertentu, akses jalan dapat mendukung penanganan kebakaran. Oleh karena itu, kedekatan dengan jalan dapat berhubungan dengan peluang munculnya api maupun kemampuan respons terhadap api sehingga regresi linear tidak dapat menentukan mekanisme mana yang bekerja.

Selain itu, informasi terkait kepadatan drainase perlu dikaji kembali. Pada penelitian ini kepadatan drainase disusun dari gabungan jaringan sungai dan irigasi. Dengan demikian, variabel kepadatan drainase merupakan kepadatan jaringan aliran air yang terpetakan, belum mencakup kanal buatan yang umumnya menjadi penyebab keringnya lahan gambut. Sungai alami, saluran irigasi, kanal yang dibendung, dan saluran yang masih aktif dapat memiliki pengaruh hidrologis yang berbeda. Beberapa literatur menjelaskan bahwa pengeringan dan perubahan kondisi muka air gambut berhubungan dengan kerentanan kebakaran, tetapi respons hidrologinya dipengaruhi curah hujan, kadar air tanah, dan karakteristik pengelolaan setempat (Goldstein, 2020; Suwito dkk., 2022; Treby dkk., 2026). Asosiasi positif dalam penelitian ini konsisten dengan salah satu kemungkinan mekanisme tersebut, bukan merupakan bukti bahwa seluruh jaringan drainase memicu karhutla.

4.2.3 Perbedaan Autokorelasi Spasial antara Unit Satuan Kelurahan dan Grid

Global Moran's I memperlihatkan autokorelasi spasial positif yang signifikan pada kepadatan titik panas dan kepadatan drainase di kedua unit satuan analisis. Kepadatan titik panas meningkat dari I sebesar 0,2145 pada tingkat kelurahan dengan p-value sebesar 0,01180 menjadi 0,6083 pada tingkat grid dengan p-value < 0,0001, sedangkan kepadatan drainase meningkat dari 0,2350 pada tingkat kelurahan dengan p sebesar 0,01197 menjadi 0,5602 pada tingkat grid dengan p-value < 0,0001. Rata-rata jarak jalan memperlihatkan perbedaan paling kuat, dari I sebesar 0,1526 dan tidak signifikan pada kelurahan (p = 0,06058) menjadi I sebesar 0,9574 dan signifikan pada grid. Hasil ini menunjukkan bahwa keserupaan nilai pada lokasi yang berdekatan lebih jelas terdeteksi pada satuan grid untuk ketiga variabel.

Perbedaan ini merupakan indikasi kuat adanya sensitivitas hasil terhadap satuan pemetaan atau *Modifiable Areal Unit Problem* (MAUP). Kelurahan mempunyai bentuk, luas, dan jumlah tetangga beragam. Agregasi data pada sebuah wilayah administrasi berpotensi meratakan perbedaan nilai di dalamnya. Sedangkan grid dengan ukuran 1 x 1 km mempertahankan lebih banyak variasi spasial lokal. Akan tetapi, perbedaan hasil Moran's I tidak dapat diatribusikan hanya pada ukuran unit dikarenakan digunakan pembobotan yang berbeda untuk tiap unit satuan analisis. Bobot "S" (*variance stabilizing*) digunakan untuk kelurahan dan "W" (*row standardized*) digunakan untuk grid, sehingga skema pembobotan juga berubah.

Nilai Moran's I dari variabel jarak terhadap jalan pada unit satuan grid yang mendekati satu (nyaris sempurna) memiliki penjelasan teknis tersendiri. Jarak dihitung dari raster *Euclidean distance*, kemudian dirata-ratakan pada grid yang berkorespondensi dengan wilayah tersebut. Data raster *euclidean distance* bersifat kontinu dan biasanya berubah bertahap antarsel. Sehingga gradasi permukaan jarak dapat memperbesar kemiripan nilai antartetangga tanpa berarti kedekatan jalan menjadi penyebab dominan karhutla. Oleh karena itu, tingginya nilai Moran's I untuk prediktor jalan tidak dapat disamakan dengan kuatnya pengaruh jalan terhadap titik panas. Nilai regresinya justru hanya dapat menjelaskan sebagian kecil variasi yang terjadi.

LISA dan Getis–Ord Gi* melengkapi statistik global dengan menunjukkan di mana pola lokal terbentuk. Pada tingkat kelurahan, LISA kepadatan titik panas hanya signifikan pada dua dari 30 kelurahan (6,67%), sedangkan pada grid terdapat 240 dari 2.759 unit (8,70%). Pada kepadatan drainase, persentase signifikan berubah dari 20,00% pada kelurahan menjadi 28,02% pada grid. Pada jarak terhadap jalan, tidak ada kelurahan dengan LISA signifikan, tetapi 990 grid (35,88%) signifikan.

Peta LISA kepadatan titik panas menempatkan Sabaru sebagai satu-satunya kelurahan High–High, sedangkan peta grid memperlihatkan beberapa *cluste* High–High yang lebih mendetail di bagian tengah–selatan dan tenggara Kota Palangka Raya. Hasil Getis–Ord Gi* kelurahan mengidentifikasi enam hotspot kepadatan titik panas, dan grid menunjukkan 261 hotspot. Perbedaan jumlah ini bukan merupakan ketidakkonsistenan metode, namun perbedaan tujuan. LISA mendeteksi klaster atau *outlier* berdasarkan deviasi lokal dan tetangga, sedangkan Gi* menilai *clustering* nilai tinggi atau rendah serta penggunaan tingkat kepercayaan 90%

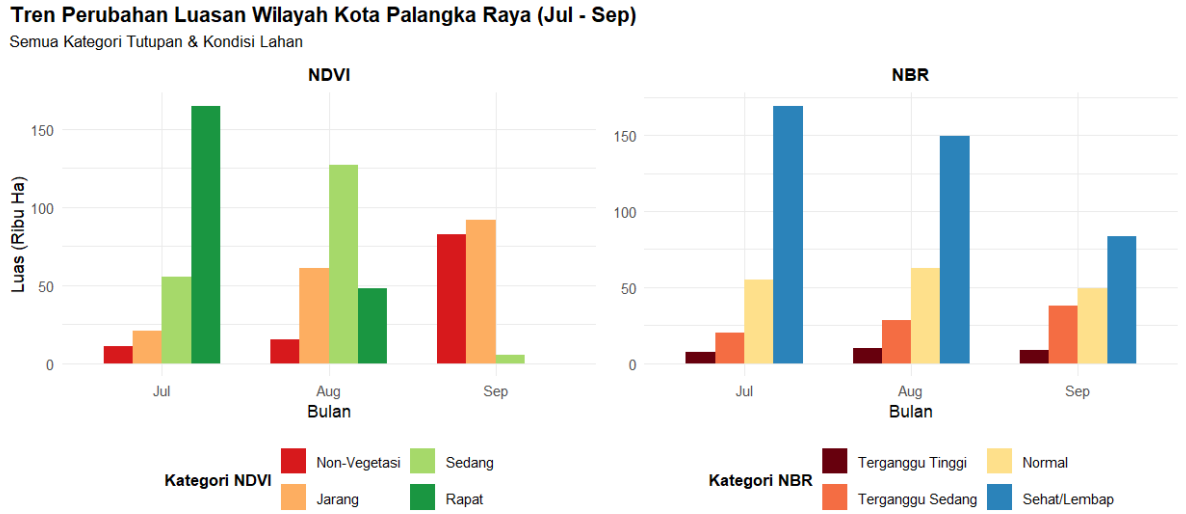
dalam Gi* juga membuat sebagian kategorinya lebih longgar daripada uji LISA yang menggunakan tingkat signifikansi 5%.

Pada analisis autokorelasi spasial variabel drainase, muncul *hotspot* statistik di Tanjung Pinang, Panarung, Kalampangan, Bereng Bengkel, Sabaru, Pahandut, Langkai, dan Kameloh Baru. Sabaru dan Kalampangan juga muncul sebagai *hotspot* statistik kepadatan titik panas, sehingga terdapat tumpang tindih pada tingkat kelurahan. Informasi ini relevan untuk penentuan wilayah observasi lanjutan, akan tetapi ko-lokasi dua peta ini belum dapat disebut korelasi spasial bivariat atau mekanisme pengeringan gambut. Analisis terkait ko-lokasi ini perlu disertai data jenis saluran, elevasi/muka air gambut, penutup lahan, serta pengecekan apakah kedua konsentrasi *hotspot* statistik benar-benar berada pada lokasi yang sama di dalam kelurahan.

Pada analisis autokorelasi spasial variabel jarak terhadap jalan, kategori hotspot Gi* justru memiliki arti *cluster area* dengan nilai jarak tinggi, bukan daerah api berkonsentrasi tinggi. Sebaliknya, *coldspot* berarti *cluster area* yang lebih dekat dengan jaringan jalan terpetakan. Pada grid, tercatat 612 hotspot dan 1.194 coldspot jarak, sementara pada tingkat kelurahan hanya tiga hotspot dan tiga coldspot. Dengan demikian, peta jarak adalah informasi aksesibilitas relatif dan tidak dapat merepresentasikan peta hotspot kebakaran.

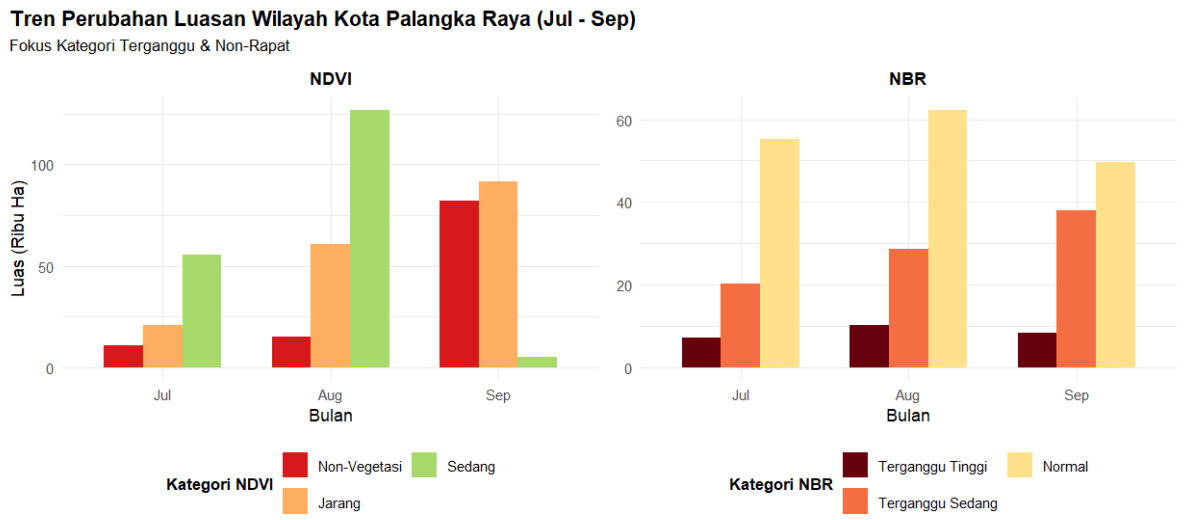
4.2.4 Keterkaitan NDVI dan NBR dengan Aktivitas Kebakaran dan Kondisi Vegetasi

Hasil pengolahan citra Sentinel-2 memberikan informasi mengenai karakteristik spektral permukaan di Kota Palangka Raya sebelum, selama, dan sesudah bulan kajian utama, yaitu Agustus 2026. Berdasarkan hasil klasifikasi *Normalized Difference Vegetation Index* (NDVI) dan *Normalized Burn Ratio* (NBR), ditemukan adanya perubahan komposisi kategori vegetasi dan kondisi lahan sepanjang Juli hingga September 2026. Perubahan tersebut dapat diamati melalui peta persebaran pada Gambar 4.12 dan 4.13, serta grafik tren perubahan luasan kategori pada Gambar 4.14 dan Gambar 4.15.



Gambar 4.14 Tren perubahan luas wilayah kategori NDVI dan NBR Kota Palangka Raya periode Juli - September 2026

Berdasarkan Gambar 4.14, distribusi kategori NDVI menunjukkan perubahan komposisi yang cukup besar selama periode pengamatan. Pada Juli 2026, kategori vegetasi rapat mendominasi wilayah teramati dengan luas mencapai 164,960 ribu hektare atau sekitar 65,4% dari total piksel valid. Luasan tersebut mengalami penurunan menjadi 47,730 ribu hektare pada Agustus atau sekitar 19,0% dari piksel valid, kemudian menjadi 0,004 ribu hektare pada September atau mendekati 0%. Sebaliknya, kategori vegetasi sedang meningkat dari 55,414 ribu hektare (22,0%) pada Juli menjadi 126,997 ribu hektare (50,6%) pada Agustus, sebelum menurun menjadi 5,252 ribu hektare (2,9%) pada September. Pergeseran ini memperlihatkan adanya perubahan distribusi nilai NDVI, terutama dari dominasi kategori vegetasi rapat pada Juli menuju vegetasi sedang pada Agustus.



Gambar 4.15 Tren perubahan luas wilayah kategori NDVI dan NBR (tanpa Rapat dan Sehat) Kota Palangka Raya periode Juli - September 2026

Perubahan yang lebih menonjol terlihat pada September 2026, ketika kategori vegetasi jarang dan non-vegetasi menjadi kategori yang paling dominan. Proporsi vegetasi jarang meningkat dari 8,3% pada Juli menjadi 24,3% pada Agustus dan 51,2% pada September. Sementara itu, kategori non-vegetasi meningkat dari 4,3% menjadi 6,0% dan kemudian 45,9% pada periode yang sama. Grafik pada Gambar 4.15, yang secara khusus menampilkan kategori selain vegetasi rapat, memperjelas peningkatan luas kategori vegetasi jarang dan non-vegetasi tersebut. Pada Agustus, vegetasi sedang masih memiliki luasan terbesar di antara kategori yang ditampilkan, sedangkan pada September kategori vegetasi jarang dan non-vegetasi mendominasi luas wilayah yang memiliki data valid. Perubahan ini menunjukkan pergeseran komposisi kategori NDVI pada area teramati, tetapi belum dapat langsung diartikan sebagai perubahan tutupan vegetasi pada seluruh wilayah penelitian.

Pada indeks NBR, perubahan komposisi kategori berlangsung dengan karakteristik yang berbeda. Berdasarkan Gambar 4.14, kategori sehat/lembap tetap memiliki luas terbesar selama ketiga bulan pengamatan, meskipun luas dan proporsinya cenderung menurun. Pada Juli, kategori tersebut mencakup 169,364 ribu hektare atau sekitar 67,2% piksel valid, kemudian menjadi 149,701 ribu hektare (59,7%) pada Agustus dan 83,375 ribu hektare (46,5%) pada

September. Sementara itu, kategori terganggu sedang menunjukkan peningkatan secara bertahap, yaitu dari 20,225 ribu hektare (8,0%) pada Juli menjadi 28,556 ribu hektare (11,4%) pada Agustus dan 37,887 ribu hektare (21,1%) pada September.

Peningkatan kategori terganggu sedang terlihat lebih jelas pada Gambar 4.15 yang tidak menyertakan kategori sehat/lembap. Pada grafik tersebut, luas kategori terganggu sedang mengalami peningkatan secara konsisten selama periode pengamatan, sedangkan kategori normal meningkat pada Agustus sebelum mengalami penurunan pada September. Adapun kategori terganggu tinggi meningkat dari 7,178 ribu hektare pada Juli menjadi 10,159 ribu hektare pada Agustus, kemudian menurun menjadi 8,463 ribu hektare pada September. Meskipun secara absolut mengalami penurunan pada bulan terakhir, proporsi kategori terganggu tinggi terhadap piksel valid tetap meningkat dari 2,8% pada Juli menjadi 4,1% pada Agustus dan 4,7% pada September. Perbedaan antara tren luas absolut dan proporsi tersebut memperlihatkan pentingnya pertimbangan luas area yang berhasil diamati pada masing-masing bulan.

Perubahan distribusi NDVI dan NBR tersebut perlu ditafsirkan dengan memperhatikan keterbatasan cakupan citra. Total luas piksel valid berkurang dari sekitar 252,1 ribu hektare pada Juli menjadi 250,7 ribu hektare pada Agustus dan 179,3 ribu hektare pada September, atau mengalami penurunan sekitar 28,9% antara Juli dan September. Berkurangnya piksel valid dapat dipengaruhi oleh proses *cloud masking* dan ketersediaan pengamatan bebas gangguan atmosfer. Oleh karena itu, penurunan luas absolut suatu kategori tidak selalu menunjukkan kehilangan tutupan lahan dengan besaran yang sama. Sebagai contoh, penurunan vegetasi rapat NDVI dari 164,960 ribu hektare menjadi 0,004 ribu hektare merupakan perubahan yang sangat ekstrem untuk periode dua bulan. Hasil tersebut memerlukan pemeriksaan lanjutan terhadap cakupan piksel yang sama, kualitas komposit citra, histogram nilai indeks, dan kesesuaian ambang klasifikasi sebelum dapat disimpulkan sebagai perubahan kondisi vegetasi secara fisik.

Secara geografis, peta NBR pada Gambar 4.13 memperlihatkan bahwa kategori dengan nilai NBR relatif rendah terutama tersebar pada koridor tengah hingga tenggara Kota Palangka Raya. Persebaran tersebut menunjukkan kesesuaian umum dengan hasil analisis Getis-Ord Gi* kepadatan titik panas pada Gambar 4.9, yang mengidentifikasi konsentrasi titik panas pada bagian tengah–selatan dan tenggara wilayah penelitian. Pola ini juga relevan dengan laporan penanganan karhutla di Kalampangan, Kereng Bangkirai, dan sejumlah wilayah Kecamatan Jekan Raya selama Agustus 2026. Meskipun demikian, kesesuaian tersebut masih bersifat deskriptif karena belum dilakukan pengujian tumpang tindih spasial menggunakan lokasi titik panas dan piksel indeks spektral dengan periode pengamatan yang sama.

Dengan demikian, hasil NDVI dan NBR memberikan informasi tambahan mengenai perubahan komposisi spektral vegetasi dan kondisi lahan selama periode penelitian. Grafik perubahan luasan pada Gambar 4.14 memperlihatkan pergeseran kategori dominan secara keseluruhan, sedangkan Gambar 4.15 memperjelas perkembangan kategori vegetasi non-rapat dan kategori NBR yang tidak termasuk sehat/lembap. Kedua grafik tersebut saling melengkapi peta persebaran bulanan dalam menggambarkan karakteristik temporal dan spasial wilayah penelitian. Namun, perubahan spektral yang teridentifikasi belum dapat seluruhnya dikaitkan

secara langsung dengan kejadian karhutla tanpa verifikasi tambahan terhadap kualitas citra, perubahan piksel yang berlokasi sama, serta data kejadian kebakaran yang terkonfirmasi.

BAB V
KESIMPULAN

5.1 Kesimpulan

Kesimpulan yang didapatkan dari penelitian ini yakni:

1. Persebaran dan kepadatan titik panas di Kota Palangka Raya pada Agustus 2026 menunjukkan konsentrasi yang tidak merata. Berdasarkan Getis–Ord Gi*, enam kelurahan dan 261 grid tergolong hotspot statistik kepadatan titik panas. Di tingkat grid, 2.367 dari 2.759 unit atau 85,79% tidak mempunyai deteksi titik panas dalam data penelitian. Konsentrasi utama berada pada bagian tengah hingga selatan dan tenggara wilayah penelitian. Beberapa lokasi hotspot kelurahan, khususnya Sabaru, Bukit Tunggal, Petuk Katimpun, Kalampangan, dan Kereng Bangkirai, sesuai secara kualitatif dengan laporan penanganan karhutla Agustus 2026. Kesesuaian ini mendukung fungsi peta sebagai informasi awal pemantauan.
2. Hubungan kepadatan titik panas dengan kepadatan drainase serta rata-rata jarak terhadap jalan berbeda menurut satuan analisis. Pada kelurahan, regresi sederhana maupun berganda tidak menunjukkan hasil signifikan pada tingkat signifikansi 5%. Pada grid, koefisien drainase positif dan jarak terhadap jalan negatif dengan signifikansi statistik yang tinggi, tetapi regresi berganda hanya menghasilkan R^2 sebesar 0,0447. Artinya, kedua prediktor secara bersama menjelaskan sekitar 4,47% variasi kepadatan titik panas grid dan belum cukup untuk menerangkan dominan atau memastikan penyebab kejadian kebakaran.
3. Analisis Global Moran's I mengidentifikasi autokorelasi positif signifikan pada kepadatan titik panas dan drainase untuk kedua satuan, serta pada jarak terhadap jalan hanya pada satuan grid. Nilai Moran's I kepadatan titik panas sebesar 0,2145 (kelurahan) dan 0,6083 (grid); drainase sebesar 0,2350 dan 0,5602; jarak terhadap jalan sebesar 0,1526 (tidak signifikan) dan 0,9574 (signifikan). Analisis LISA dan Getis–Ord Gi* menunjukkan detail klaster yang berbeda antarunit, menegaskan sensitivitas hasil terhadap satuan dan matriks bobot spasial. Grid memberi penggambaran lokal yang lebih rinci, tetapi tidak dapat dinyatakan otomatis lebih akurat tanpa validasi.
4. Indeks NDVI dan NBR Sentinel-2 memperlihatkan perubahan distribusi kategori spektral Juli–September 2026. Proporsi piksel valid NDVI vegetasi rapat menurun dari 65,4% pada Juli menjadi 19,0% pada Agustus dan mendekati nol pada September, sedangkan NBR sehat/lembap berubah dari 67,2% menjadi 59,7% dan 46,5%. Akan tetapi, luas piksel valid September hanya sekitar 179,3 ribu ha dibanding sekitar 252,1 ribu ha pada Juli. Oleh sebab itu, besaran perubahan kategori belum dapat disimpulkan sebagai luas vegetasi rusak atau area terbakar yang terverifikasi.

5.2 Saran

Berdasarkan penelitian yang telah dilakukan, berikut merupakan saran untuk penelitian selanjutnya.

1. Penelitian berikutnya disarankan menambahkan data validasi langsung (contoh: data dari BPBD) yang memiliki tanggal, koordinat, kondisi permukaan, dan luas terbakar.
2. Perhitungan variabel drainase sebaiknya memisahkan sungai alami, irigasi, kanal buatan, kanal aktif, dan kanal yang sudah disekat.
3. Hubungan statistik dapat ditelaah lebih lanjut menggunakan model pendekatan nonlinier serta model regresi spasial apabila residual OLS menunjukkan autokorelasi.
4. Analisis sensitivitas skala yang berkaitan dengan MAUP perlu dilakukan pada lebih dari satu ukuran grid, misalnya 500 m, 1 km, dan 2 km, dengan skema ketetanggaan dan standardisasi bobot yang sama dengan analisis kelurahan.
5. Untuk analisis indeks spektral, apabila data dari Sentinel-2 memiliki tutupan awan yang padat pada bulan analisis maka dapat menggunakan alternatif berupa data Landsat untuk dihitung indeks spektral.

DAFTAR PUSTAKA

(autocitation)

Anselin, L. (1995). Local Indicators of Spatial Association—LISA. *Geographical Analysis*, *27*(2), 93–115. https://doi.org/10.1111/j.1538-4632.1995.tb00338.x

ANTARA. (2026a, Agustus 20). BPBD Palangka Raya tangani 298 kejadian kebakaran lahan. *ANTARA*. https://www.antaranews.com/berita/5702731/bpbd-palangka-raya-tangani-298-kejadian-kebakaran-lahan

ANTARA. (2026b, September 17). BPBD Palangka Raya: 1.201 hektare lahan terbakar akibat 567 karhutla. *ANTARA*. https://kalteng.antaranews.com/amp/berita/842552/bpbd-palangka-raya-1201-hektare-lahan-terbakar-akibat-567-karhutla

ANTARA. (2026c, Oktober 21). BPBD Palangka Raya kerahkan alat berat dalam upaya pemadaman karhutla. *ANTARA*. https://kalteng.antaranews.com/berita/846773/bpbd-palangka-raya-kerahkan-alat-berat-dalam-upaya-pemadaman-karhutla

Badan Pusat Statistik Kota Palangka Raya. (2026). *Luas Daerah dan Jumlah Pulau Menurut Kecamatan di Kota Palangka Raya, 2025*. https://palangkakota.bps.go.id/id/statistics-table/3/VUZwV01tSlpPVlpsWlRKbmMxcFhhSGhEVjFoUFFUMDkjMw%3D%3D/total-area-and-number-of-islands-by-subdistrict-in-palangka-raya-municipality--2018.html

Dinas Lingkungan Hidup Kota Palangka Raya. (2025). *Tahun 2024, Angka Kejadian Karhutla di Palangka Raya Menurun Signifikan*. https://dlh.palangkaraya.go.id/tahun-2024-angka-kejadian-karhutla-di-palangka-raya-menurun-signifikan/

European Space Agency. (t.t.). *Sentinel-2*. Diambil https://www.esa.int/Applications/Observing_the_Earth/Copernicus/Sentinel-2/

Getis, A., & Ord, J. K. (1992). The Analysis of Spatial Association by Use of Distance Statistics. *Geographical Analysis*, *24*(3), 189–206. https://doi.org/10.1111/j.1538-4632.1992.tb00261.x

Goldstein, J. E. (2020). Beyond slash-and-burn: The roles of human activities, altered hydrology and fuels in peat fires in Central Kalimantan. *Singapore Journal of Tropical Geography*, *41*, 190–208. https://doi.org/10.1111/sjtg.12319

Lillesand, T. M., Kiefer, R. W., & Chipman, J. W. (2015). *Remote Sensing and Image Interpretation* (7th edition). John Wiley & Sons. https://www.wiley-vch.de/en/areas-interest/engineering/remote-sensing-and-image-interpretation-978-1-118-34328-9

Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). *Introduction to Linear Regression Analysis* (6 ed.). John Wiley & Sons, Inc.

Moran, P. A. P. (1950). Notes on Continuous Stochastic Phenomena. *Biometrika*, *37*(1–2), 17–23. https://doi.org/10.1093/biomet/37.1-2.17

NASA. (t.t.). *VIIRS/NPP Active Fires 6-Min L2 Swath 375m V002* [Dataset]. https://doi.org/10.5067/VIIRS/VNP14IMG.002

NASA FIRMS. (t.t.). *VIIRS fire hotspots: Product description*. NASA FIRMS. Diambil https://firms.modaps.eosdis.nasa.gov/content/descriptions/FIRMS_VIIRS_Firehotspots.html

Page, S. E., Siegert, F., Rieley, J. O., Boehm, H.-D. V., Jaya, A., & Limin, S. (2002). The Amount of Carbon Released from Peat and Forest Fires in Indonesia during 1997. *Nature*, *420*(6911), 61–65. https://doi.org/10.1038/nature01131

Pantau Gambut. (t.t.). *Rentan Terbakar*. Diambil https://pantaugambut.id/pelajari/rentan-terbakar

Pantau Gambut. (2026). *Titik panas bulan Agustus 2026 meningkat 1.006 persen*. Pantau Gambut. https://pantaugambut.id/publikasi/titik-panas-bulan-agustus-2026-meningkat-1006-persen

Pebesma, E. (2018). Simple Features for R: Standardized Support for Spatial Vector Data. *The R Journal*, *10*(1), 439–446. https://doi.org/10.32614/RJ-2018-009

Pemerintah Kota Palangka Raya. (2025, Mei 21). *Pemko Palangka Raya Gelar Konsultasi Publik Bahas Raperda Pengendalian Karhutla*. https://palangkaraya.go.id/pemko-palangka-raya-gelar-konsultasi-publik-bahas-raperda-pengendalian-karhutla/

R Project. (t.t.). *What is R?* R Foundation for Statistical Computing. Diambil https://www.r-project.org/about.html

RRI. (2026a, Agustus 15). Cegah karhutla meluas, Polsek Sabangau padamkan titik panas di Kalampangan. *RRI*. https://rri.co.id/palangkaraya/regional/2654645/cegah-karhutla-meluas-polsek-sabangau-padamkan-titik-panas-di-kalampangan

RRI. (2026b, Agustus 15). Titik panas di Bukit Tunggal, waspada karhutla meluas. *RRI*. https://rri.co.id/palangkaraya/regional/2653677/titik-panas-di-bukit-tunggal-waspada-karhutla-meluas

RRI. (2026c, Agustus 20). Kapolresta Palangka Raya dampingi Menhut tinjau karhutla di Petuk Katimpun. *RRI*. https://rri.co.id/palangkaraya/regional/2665247/kapolresta-palangka-raya-dampingi-menhut-tinjau-karhutla-di-petuk-katimpun

RRI. (2026d, Agustus 20). Lahan gambut kembali berasap, Polsek Sabangau gerak cepat padamkan api. *RRI*. https://rri.co.id/palangkaraya/berita-lain/2667082/lahan-gambut-kembali-berasap-polsek-sabangau-gerak-cepat-padamkan-api

RRI. (2026e, Agustus 28). Karhutla tidak padam, Polresta turut berjibaku padamkan api. *RRI*. https://rri.co.id/palangkaraya/hukum/hukum/2687936/karhutla-tidak-padam-polresta-turut-berjibaku-padamkan-api

RRI. (2026f, Agustus 31). Dikepung karhutla, unsur pimpinan Palangka Raya gelar monev. *RRI*. https://rri.co.id/palangkaraya/hukum/hukum/2693169/dikepung-karhutla-unsur-pimpinan-palangka-raya-gelar-monev

RRI. (2026g, Agustus 31). Karhutla meluas, warga Petuk Katimpun alami gangguan kesehatan akibat kabut asap. *RRI*. https://rri.co.id/palangkaraya/berita-lain/2694672/karhutla-meluas-warga-petuk-katimpun-alami-gangguan-kesehatan-akibat-kabut-asap

RRI. (2026h, Agustus 31). Tim gabungan padamkan karhutla Sabangau. *RRI*. https://rri.co.id/palangkaraya/hukum/hukum/2696881/tim-gabungan-padamkan-karhutla-sabangau

Suwito, D., Suratman, & Poedjirahajoe, E. (2022). The effects of canal blocking on hydrological restoration in degraded peat swamp forest post-forest fires in Central Kalimantan. *IOP Conference Series: Earth and Environmental Science*, *1018*, 012027. https://doi.org/10.1088/1755-1315/1018/1/012027

Treby, S., Graham, L. L. B., Ningsih, S. N. A., Thomas, A., & Grover, S. P. P. (2026). Soil hydrology in a drained tropical peatland in Central Kalimantan, Indonesia: Implications for land management. *Pedosphere*. https://doi.org/10.1016/j.pedsph.2026.02.009

Tucker, C. J. (1979). Red and Photographic Infrared Linear Combinations for Monitoring Vegetation. *Remote Sensing of Environment*, *8*(2), 127–150. https://doi.org/10.1016/0034-4257(79)90013-0

(reading)

Anselin, L. (1988). Lagrange Multiplier Test Diagnostics for Spatial Dependence and Spatial Heterogeneity. Geographical Analysis, 20(1), 1–17. https://doi.org/10.1111/j.1538-4632.1988.tb00159.x

Badan Penanggulangan Bencana dan Pemadam Kebakaran Provinsi Kalimantan Tengah. (2026a, Juli 16). BPB-PK Kalteng Perkuat Penanganan Karhutla Selama Musim Kemarau 2026. Multimedia Center Provinsi Kalimantan Tengah. https://mmc2.kalteng.go.id/berita/read/50852/bpb-pk-kalteng-perkuat-penanganan-karhutla-selama-musim-kemarau-2026

Badan Penanggulangan Bencana dan Pemadam Kebakaran Provinsi Kalimantan Tengah. (2026b, September 9). BPB-PK Kalteng Kerahkan 6 Helikopter dan Pesawat OMC Antisipasi Meluasnya Karhutla. Multimedia Center Provinsi Kalimantan Tengah. https://mmc2.kalteng.go.id/berita/read/51356/bpb-pk-kalteng-kerahkan-6-helikopter-dan-pesawat-omc-antisipasi-meluasnya-karhutla

Badan Penanggulangan Bencana dan Pemadam Kebakaran Provinsi Kalimantan Tengah. (2026c, Oktober 19). BPB-PK Kalteng Catat 66 Kejadian Karhutla dalam Sehari. Multimedia Center Provinsi Kalimantan Tengah. https://mmc2.kalteng.go.id/berita/read/51709/bpb-pk-kalteng-catat-66-kejadian-karhutla-dalam-sehari

Esri. (t.t.). How Hot Spot Analysis (Getis-Ord Gi*) works. ArcGIS Pro Documentation. Diambil https://doc.esri.com/en/arcgis-pro/latest/tool-reference/spatial-statistics/h-how-hot-spot-analysis-getis-ord-gi-spatial-stati.html

Hijmans, R. J., Brown, A., & Barbosa, M. (2026). terra: Spatial Data Analysis (Versi R package version 1.9-34) [Perangkat lunak]. https://doi.org/10.32614/CRAN.package.terra

U.S. Geological Survey. (t.t.-b). Post-fire mapping glossary: NBR and differenced NBR. U.S. Geological Survey. Diambil https://burnseverity.cr.usgs.gov/glossary

LAMPIRAN

Informasi mengenai data yang digunakan serta kode yang digunakan dalam pemrosesan telah diunggah pada https://github.com/AntaraAntariksa/PDS-midterm-2026.git untuk meringkas bagian lampiran.